



MINISTÉRIO DA CIÊNCIA, TECNOLOGIA, INOVAÇÕES E COMUNICAÇÕES
INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS

DATA CUBE ALGORITHM FOR HIGH SEQUENTIALITY SATELLITE TELEMETRY DATA ANALYSIS

Yuri Matheus Dias Pereira

Dissertação de Mestrado do Curso
de Pós-Graduação em Engenharia
e Gerenciamento de Sistemas Es-
paciais. Orientada pelo Dr. Mauri-
cio Gonçalves Vieira Ferreira e pelo
Dr. Rodrigo Rocha Silva

URL of the original document:

[<http://urlib.net/>](http://urlib.net/)

INPE
São José dos Campos
2021

PUBLISHED BY:

Instituto Nacional de Pesquisas Espaciais - INPE

Gabinete do Diretor (GB)

Serviço de Informação e Documentação (SID)

Caixa Postal 515 - CEP 12.245-970

São José dos Campos - SP - Brasil

Tel.:(012) 3945-6923/6921

Fax: (012) 3945-6919

E-mail: pubtc@sid.inpe.br

BOARD OF PUBLISHING AND PRESERVATION OF INPE INTELLECTUAL PRODUCTION - CEPPII (PORTARIA Nº 176/2018/SEI-INPE):**Chairperson:**

Marciana Leite Ribeiro - Serviço de Informação e Documentação (SID)

Members:

Dr. Gerald Jean Francis Banon - Coordenação Observação da Terra (OBT)

Dr. Amauri Silva Montes - Coordenação Engenharia e Tecnologia Espaciais (ETE)

Dr. André de Castro Milone - Coordenação Ciências Espaciais e Atmosféricas (CEA)

Dr. Joaquim José Barroso de Castro - Centro de Tecnologias Espaciais (CTE)

Dr. Manoel Alonso Gan - Centro de Previsão de Tempo e Estudos Climáticos (CPT)

Dr^a Maria do Carmo de Andrade Nono - Conselho de Pós-Graduação

Dr. Plínio Carlos Alvalá - Centro de Ciência do Sistema Terrestre (CST)

DIGITAL LIBRARY:

Dr. Gerald Jean Francis Banon - Coordenação de Observação da Terra (OBT)

Clayton Martins Pereira - Serviço de Informação e Documentação (SID)

DOCUMENT REVIEW:

Simone Angélica Del Ducca Barbedo - Serviço de Informação e Documentação (SID)

Yolanda Ribeiro da Silva Souza - Serviço de Informação e Documentação (SID)

ELECTRONIC EDITING:

Marcelo de Castro Pazos - Serviço de Informação e Documentação (SID)

André Luis Dias Fernandes - Serviço de Informação e Documentação (SID)



MINISTÉRIO DA CIÊNCIA, TECNOLOGIA, INOVAÇÕES E COMUNICAÇÕES
INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS

DATA CUBE ALGORITHM FOR HIGH SEQUENTIALITY SATELLITE TELEMETRY DATA ANALYSIS

Yuri Matheus Dias Pereira

Dissertação de Mestrado do Curso
de Pós-Graduação em Engenharia
e Gerenciamento de Sistemas Es-
paciais. Orientada pelo Dr. Mauri-
cio Gonçalves Vieira Ferreira e pelo
Dr. Rodrigo Rocha Silva

URL of the original document:

[<http://urlib.net/>](http://urlib.net/)

INPE
São José dos Campos
2021

Cataloging in Publication Data

Sobrenome, Nomes.

Cutter Data Cube Algorithm for High Sequentiality Satellite Teleme-
try Data Analysis / Nome Completo do Autor1; Nome Completo
do Autor2. – São José dos Campos : INPE, 2021.
xxii + 67 p. ; ()

Dissertação ou Tese (Mestrado ou Doutorado em Nome do
Curso) – Instituto Nacional de Pesquisas Espaciais, São José dos
Campos, AAAA.

Orientador : José da Silva.

1. Palavra chave. 2. Palavra chave 3. Palavra chave. 4. Palavra
chave. 5. Palavra chave I. Título.

CDU 000.000



Esta obra foi licenciada sob uma [Licença Creative Commons Atribuição-NãoComercial 3.0 Não Adaptada](#).

This work is licensed under a [Creative Commons Attribution-NonCommercial 3.0 Unported License](#).

**ATENÇÃO! A FOLHA DE
APROVAÇÃO SERÁ INCLU-
IDA POSTERIORMENTE.**

Mestrado ou Doutorado em Nome do
Curso

“But I try not to think with my gut. If I’m serious about understanding the world, thinking with anything besides my brain, as tempting as that might be, is likely to get me into trouble. It’s OK to reserve judgment until the evidence is in.”

CARL SAGAN E ANN DRUYAN
em “O Mundo Assombrado pelos Demônios:
A Ciência Vista Como Uma Vela no Escuro”, 1995

ACKNOWLEDGEMENTS

- Mauricio
- Rodrigo
- Família (dos dois lados)
- Bruno e Gabriela
- Italo, Isomar e Danilo
- Comissão WETE e CubeDesign
- Jun, Pascote, Maria (?) e todos do CCS
- Seguranças do INPE (Em especial ao Eduardo)
- Membros do CITAR pelos almoços
- Todos os membros da biblioteca do INPE

Ao INPE e todos os funcionários que proveram todas a infraestrutura necessária para este trabalho.

- CAPES
- Secretaria de Pós-Graduação?

ABSTRACT

Satélites são monitorados pelas equipes de solo via pacotes de telemetria, que informam o estado atual dos equipamentos e permitem avaliar a capacidade do satélite de continuar a sua missão. Esses pacotes de telemetria constituem um corpo de dados de tamanho e alta complexidade, sendo que satélites que operados por vários anos geram dados históricos de grande volume, ainda úteis para as atividades de operação. O volume de dados históricos de telemetria disponíveis ao INPE atualmente é estimado em ao menos 3 *terabytes* no total, com tendência a crescer nos próximos anos. Esta proposta apresenta o uso de cubo de dados como solução para executar consultas e análises sobre esses dados. Os conceitos da área de cubo de dados são apresentados, bem como uma revisão de como outros operadores de satélite estão lidando com grandes volumes, variedades e velocidade de atualização de dados, cenário que define um contexto de *Big Data* para o domínio de controle de satélites. Devido a característica de alta dimensionalidade dos dados de telemetria, algoritmos clássicos da área do cubo de dados tem dificuldade em responder consultas com resultado satisfatório para os operadores de satélite. Assim, neste trabalho é proposto identificar as consultas que são de interesse dos operadores de satélite, criar uma modelagem multidimensional para os dados de telemetria utilizando de cubo de dados, e avaliar quais são os algoritmos de construção do cubo que conseguiriam suprir as necessidades dos dados. Também são apresentados os resultados alcançados até o momento, bem como o planejamento para a continuação do trabalho.

Keywords: cubo de dados. *Big Data*. Satélites. Telemetrias. Operação de Satélites.

DATA CUBE ALGORITHM FOR HIGH SEQUENTIALITY SATELLITE TELEMETRY DATA ANALYSIS

RESUMO

Abstract

Palavras-chave: Atmospheric turbulence. WETAMC campaign. LBA project. Chaotic behavior. Chaotic attractor.

LIST OF FIGURES

	<u>Page</u>
1.1 Estimativa de geração anual de dados pelos satélites do INPE	2
1.2 Estimativa do volume de dados histórico de telemetria de todos os satélites	2
2.1 Exemplo de um cubo de dados	12
2.2 Células de agregação em um cubo de dados	12
2.3 Esquema estrela	13
2.4 Esquema floco de neve	14
2.5 Esquema constelação de fatos	15
2.6 Operações <i>OLAP</i> em um cubo de dados	17
2.7 Computação de cubo de dados através da estratégia <i>Top-Down</i>	19
2.8 Computação de cubo de dados através da estratégia <i>Bottom-up</i>	20
3.1 Fluxo de dados em uma arquitetura de <i>Big Data</i>	22
3.2 Exemplo de uma tabela dimensional e a respectiva lista de índices invertidos	27
4.1 Query 1 results	38
4.2 Query 2 results	39
4.3 Query 3 results	40
4.4 Query 4 results	41
4.5 Query 5 results	42
A.1 Set Intersection Algorithm results	62

LIST OF TABLES

	<u>Page</u>
3.1 Operations Data	21
3.2 Operadores de Satélite e Arquiteturas de Big Data	24
4.1 Telemetries overview	33
4.2 Queries overview	35
4.3 Cube representations used in the experiment	37
5.1 IntervalFrag x Frag-Cubing, memory consumption in KiB	46
5.2 IntervalFrag x Frag-Cubing, query response times in ms	46
6.1 Preferred algorithm to use	47
A.1 Set Intersection Results, in milliseconds	62
A.1 Resulting published work	65

LIST OF ABBREVIATIONS

DW	– <i>Data Warehouse</i> (Armazém de Dados)
OLAP	– <i>On-Line Analytical Processing</i> (Processamento Analítico Online)
OLPT	– <i>On-Line Transaction Processing</i> (Processamento Online de Transações)
NoSQL	– "Não apenas SQL"
TAD	– Tipo Abstrato de Dados
ROLAP	– <i>Relational OLAP</i>
MOLAP	– <i>Multidimensional OLAP</i>
HOLAP	– <i>Hybrid OLAP</i>
DBMS	– <i>DataBase Management System</i>
TLE	– <i>Two Line Element</i>
TID	– <i>Tuple Identifier</i> (Identificador de Tupla)
CSV	– Valores Separados por Vírgula
INPE	– Instituto Nacional de Pesquisas Espaciais
CCS	– Centro de Controle de Satélites
SCD	– Satélite de Coleta de Dados
CBERS	– Satélite Sino-Brasileiro de Recursos Terrestres
AMZ	– Amazônia
NASA	– <i>National Aeronautics and Space Administration</i>
NOAA	– <i>National Oceanic and Atmospheric Administration</i>
L-3	– <i>Level 3</i>
ESA	– <i>European Space Operations Centre</i>
EUMETSAT	– <i>European Organisation for the Exploitation of Meteorological Satellites</i>
AWS	– <i>Amazon Web Services</i>
HDFS	– <i>Hadoop Distributed FileSystem</i>
CSMT	– <i>China Satellite Marine Track & Control Department</i>
SISSET	– <i>Shandong Institute of Space Electronic Technology</i>

LIST OF SYMBOLS

a	–	primeira contante
b	–	segunda constante
ρ	–	densidade de um fluido
ν	–	viscosidade cinemática
R_e	–	número de Reynolds
α	–	constante de Kolmogorov
k	–	número de onda
K	–	curtose
D_0	–	dimensão de contagem de caixas
D_1	–	dimensão de informação
D_2	–	dimensão de correlação
λ_1	–	expoente de Lyapunov dominante

CONTENTS

	<u>Page</u>
1 INTRODUÇÃO	1
1.1 Objetivos	4
1.2 Organização da proposta	5
2 FUNDAMENTAÇÃO	7
2.1 Operação de satélites	7
2.2 <i>Big Data</i>	8
2.3 <i>Data Warehouse</i>	9
2.4 <i>OLAP</i>	9
2.5 Cubo de dados	11
2.5.1 Células do cubo de dados	12
2.5.2 Modelagem dimensional	13
2.5.3 Hierarquias de conceito	14
2.5.4 Medidas	15
2.5.5 Operações OLAP	16
2.5.6 Computação do cubo de dados	17
3 RELATED WORKS	21
3.1 Operations Data	21
3.1.1 Data Flow	21
3.2 Análise de dados em outros operadores de satélite	23
3.2.1 Análise de dados no INPE	25
3.3 Computação do cubo de dados	25
3.3.1 <i>Frag-Cubing</i>	27
4 Query Partition	29
4.1 Algorithm	29
4.1.1 Aggregation Generator	29
4.1.2 Relationship Strength Calculation	30
4.2 Queries	32
4.2.1 Q1	32
4.2.2 Q2	33
4.2.3 Q3	34

4.2.4	Q4	34
4.2.5	Q5	34
4.2.6	Summary	35
4.3	Experimental Validation	35
4.3.1	Dataset and Method	35
4.3.2	Results	37
4.3.2.1	Q1	38
4.3.2.2	Q2	38
4.3.2.3	Q3	39
4.3.2.4	Q4	40
4.3.2.5	Q5	41
4.4	Summary and Analysis	42
5	IntervalFrag	45
5.1	Using Intervals in Inverted Indexes	45
5.2	Algorithm	45
5.3	Results	45
6	Analysis and Discussion	47
7	CONCLUSIONS	51
7.1	Main contributions	51
7.2	Future work	51
7.3	Final thoughts	52
	REFERENCES	53
	APPENDIX A - INTERSECTION ALGORITHMS	61
A.1	Problem	61
A.2	Algorithms	61
A.3	Experiments	61
	ANNEX A - PUBLICATIONS.	65

1 INTRODUÇÃO

O Centro de Controle de Satélites (CCS) é um departamento pertencente ao Instituto Nacional de Pesquisas Espaciais (INPE) atualmente monitora e controla os seguintes satélites: a família do Satélite de Coleta de Dados (SCD), composta de dois satélites SCD-1 e SCD-2, e a família do Satélite Sino-Brasileiro de Recursos Terrestres (CBERS), com apenas o quinto satélite em operação atualmente, o CBERS-4. Estes satélites realizam passagens sobre as estações terrenas do INPE, durante o qual o CCS recebe dados do estado do satélite, chamados de telemetrias, e envia telecomando, utilizados para controlar o satélite, bem como realiza atividades de manutenção e estimativa, como medidas de velocidade e posição de cada satélite (AZEVEDO; AMBRÓSIO, 2010).


Dados de telemetria geralmente carregam medidas de sensores e verificações de saúde dos instrumentos, como temperatura das baterias, corrente de algum subsistema, se um dado equipamento está ativo ou não, bem como dados que os operadores e engenheiros acham necessários para a operação, entre outros (LARSON; WERTZ, 1999). Estes dados precisam ser guardados por toda a vida do satélite, sendo que para satélites que estão em funcionamento por vários anos adquirem um elevado volume de dados, que deve ser analisado. No caso dos satélites da família SCD, o SCD-1 já estando operacional por mais de 25 anos, e continuando a gerar dados, atualmente gera um volume aproximado de 7GB por ano.

Para satélites mais complexos como os da família CBERS, que possuem mais de 4 mil telemetrias sendo monitoradas. Com os lançamentos futuros do CBERS-4A e do Amazônia-1, o volume de dados e a complexidade da análise dos mesmos deve aumentar, criando novas necessidades de operação (FILHO et al., 2017).

A figura 1.1 mostra uma estimativa simples da geração histórica de dados de telemetria no CCS. Essa estimativa foi feita utilizando dos dados não comprimidos a partir da disponibilidade dos mesmos. Ela também assume que o Amazônia-1 vai gerar um volume de dados de telemetria similar ao gerado do CBERS.

Dessa estimativa, obtemos o total de dados de telemetria disponíveis para a análise no CCS considerando uma taxa constante dos satélites, apresentados na figura 1.2. É importante ressaltar que a grande maioria desses dados não está disponível para consulta pelo usuário, visto que somente os dados de alguns poucos anos da operação estão disponíveis para os operadores e engenheiros, necessitando de trabalho significativo para analisar dados do passado.

Figure 1.1 - Estimativa de geração anual de dados pelos satélites do INPE




Volume estimado de geração de dados por cada ano de operação de cada satélite.

SOURCE: Produção do autor.

Esses dados devem ser propriamente tratados para que não virem “*dark data*”, termo que denota quaisquer tipo de dados que não são de fácil acesso para os seus usuários em potencial (HEIDORN, 2008).

Figure 1.2 - Estimativa do volume de dados histórico de telemetria de todos os satélites



Volume total estimado de dados de telemetria gerados por todos os satélites.

SOURCE: Produção do autor.

Esses dados entram na definição de *Big Data*, pois possuem um grande volume, são gerados continuamente, possuem formatos diversos, sua análise é de alto valor e existe uma incerteza quanto a qualidade dos dados devido a problemas de comunicação e degradação dos instrumentos. Essas características são denotadas pelos cinco Vs do *Big Data*: Volume, Variedade, Velocidade, Valor e Veracidade (EMANI et al., 2015).

Considerando que todos os dados já estivessem no banco de dados, propriamente formatados e prontos para a análise, ainda restariam grandes problemas: com um banco de dados na ordem dos *terabytes*, consultas sobre um número elevado de telemetrias ou que precisem de dados de vários anos poderiam demorar dias, ou mais, para serem executadas.

Deste modo, é necessário criar uma estrutura que permita a análise e consulta desses dados de uma forma estruturada e que tenha desempenho satisfatório. As tecnologias de *Data Warehouse* (DW) e *Online Analytical Processing* (OLAP) tem demonstrado capacidade e experiência para atingir esses objetivos (BIMONTE, 2016), inclusive na área espacial (YVERNES, 2018). Essas tecnologias executam a generalização de dados agregando enormes quantidade de dados em vários níveis de abstração, assim tornam elementos essenciais de apoio à decisão e atraem a atenção tanto da indústria como das comunidades de pesquisa. Sistemas OLAP, que são tipicamente dominados por consultas complexas que envolvem operadores *group-by* e operadores de agregações, são as principais características entre essas ferramentas.

Sistemas OLAP são baseados em um modelo multidimensional chamado de cubo de dados, que é uma generalização do operador *group-by* sobre todas as combinações possíveis das dimensões, com variados níveis de granularidade (GRAY et al., 1996). Cada dimensão é uma perspectiva de decisão sobre os dados, sendo formada por um subconjunto de atributos. Cada combinação é chamada de um subcubo, que correspondem a um conjunto de células descritas como tuplas sobre as dimensões do subcubo. Além das dimensões, cada tupla contém um fato, também chamado de medida, que representa o que será medido no processo de análise.

Cada dimensão pode estar organizada em uma hierarquia para facilitar a análise. Por exemplo, uma dimensão tempo pode ser dividida em “dia < mês < ano”, com ano sendo o nível mais genérico. Essa prática visa facilitar a interpretação dos dados pelos usuários. Medidas são atributos associados a uma combinação de dimensões, sendo geradas de forma estatística.

Tecnologias OLAP são caracterizadas pela habilidade em responder consultas de apoio a decisão de forma eficiente (HAN et al., 2011). Para atingir isso, o cubo de dados deve ser materializado antes da execução da consulta. Isso significa que as combinações de dimensões são computadas previamente, assim gerando o cubo de dados completo. Porém, essa abordagem possui um custo computacional exponencial em relação ao número de dimensões, assim a materialização completa do cubo envolve um grande número de células e um tempo substancial para a sua execução.

Dados de satélite são caracterizados pela sua alta dimensionalidade, onde um satélite pode precisar rastrear milhares de telemetrias. Por exemplo, supondo um satélite com $n = 100$ telemetrias, e cada telemetria representando uma dimensão, teremos 2^{100} possíveis subcubos para a implementação de um cubo de dados. Supondo uma cardinalidade, o número de valores diferentes em cada telemetria, como sendo de 100, teremos $101^{100} \approx 10^{200}$ células para cada dimensão. Devido ao controle ativo pelos operadores de satélite, os dados são concentrados em alguns valores que se repetem frequentemente, sendo que isso é chamado de *skew*.

Dessa forma, conseguir calcular e manter um cubo de dados é um problema exponencial, e reduzir o seu consumo de memória e tempo de computação é de fundamental importância para desenvolver um sistema OLAP. Para a área espacial essa necessidade é maior: a maior parte dos algoritmos de computação do cubo tem problemas em lidar com mais do que 15 dimensões (SILVA, 2015).

1.1 Objetivos

Assim, este trabalho tem como objetivo estabelecer um método para processamento de cubos de dados para a área espacial, para que o processamento de consultas OLAP sejam executadas de forma eficiente considerando-se a alta dimensionalidade, elevado número de tuplas, alto *skew* e alta cardinalidade dos dados.

Assim é necessário identificar quais são as consultas de interesse dos operadores de satélite e quais são as análises que devem ser feitas pelos mesmos. Disso será criada uma representação dimensional dos dados de telemetria em uma estrutura do cubo de dados, e algoritmos de construção do cubo devem ser avaliados para identificar qual é o mais apropriado para responder as consultas.

Como resultados esperados deste trabalho teremos a avaliação dos algoritmos de construção do cubo nos dados de alta dimensionalidade, com a adequabilidade do uso de cubo de dados como uma solução para operadores executarem as consultas

analíticas mais estratégicas para as operações de satélites.

1.2 Organização da proposta

Os capítulos restantes desta proposta estão organizados da seguinte maneira:

- Capítulo 2: Este capítulo apresenta os conceitos e fundamentos teóricos desta proposta, como os conceitos relevantes de operação de satélites, *Data Warehouse*, *Big Data* e cubo de dados.
- Capítulo 3: Neste capítulo os trabalhos correlatos de cubo de dados são apresentados, bem como as arquiteturas que outros operadores de satélite estão implementando.
- Capítulo 4: Neste capítulo a proposta é apresentada e seus conceitos principais explicados.
- Capítulo 5: Esse capítulo apresenta os resultados alcançados até o momento, apresentando os *software* utilizados.
- Capítulo 6: Com base nos resultados intermediários alcançados, esse capítulo apresentará as conclusões obtidas, bem como as direções de implementação para o resto do trabalho.

2 FUNDAMENTAÇÃO

Este capítulo apresenta os conceitos fundamentais relacionados a essa proposta, começando pela operação dos satélites na seção 2.1, apresentando a definição de *Big Data* na seção 2.2, e os os conceito de *Data Warehouse* na seção 2.3, *OLAP* na seção 2.4 e cubo de dados na seção 2.5.

2.1 Operação de satélites

Um satélite é dividido em dois módulos: o módulo de serviço e a carga útil. O módulo de serviço compõe tudo necessário para o funcionamento dos equipamentos de bordo, como o sistema de geração de energia, o sistema de comunicação com o solo, o computador de bordo, etc. A carga útil compõe todos os equipamentos necessários para cumprir os objetivos da missão, sendo esses sensores, câmeras, telescópios, etc (LARSON; WERTZ, 1999).

Um satélite gera dois tipos diferentes de dados: dados da carga útil e dados de telemetria. Os dados da carga útil são os dados gerados para cumprir a missão do satélite, sendo que eles podem ser fotos tiradas para o sensoriamento remoto, fotos tiradas por telescópios, dados de comunicação caso este seja o foco da missão entre outros (LARSON; WERTZ, 1999). Os dados de telemetria são os dados de monitoramento do estado de saúde e do funcionamento dos equipamentos do satélite. Esses dados são coletados pelo computador de bordo do satélite, e são enviados para as estações de solo via sistemas de telecomunicação.

Os dados de telemetria compõe usualmente medidas de sensores nos equipamentos do satélite, informações coletadas pelo computador de bordo (como se um instrumento está ligado ou não), e outros dados cuja coleta foi definida como relevante para a operação do satélite. Dependendo da missão, outras medidas podem ser classificadas como telemetria, como por exemplo câmeras voltadas para o satélites, radares para a detecção de possíveis colisões, etc (KRAG et al., 2017).

Esses dados devem ser analisados pelos operadores de satélite, que são os responsáveis pelo monitoramento e operação do satélite, em solo após recebimento no centro de controle. Essa análise visa garantir que o satélite está executando suas tarefas como deveria, e que o seu estado de saúde permite a continuação da missão. Neste trabalho, será utilizada a análise feita pelos operadores de satélite somente nos dados de telemetria, que é uma análise não trivial dadas as características dos dados, classificados como *Big Data*.

2.2 *Big Data*

A aplicação do conceito de *Big Data* vem evoluindo ao longo dos anos, e para este trabalho será utilizada a definição dos 5 Vs: Volume, Variedade, Velocidade, Valor e Veracidade (EMANI et al., 2015). Em detalhes:

- **Volume:** esse termo geralmente especifica uma quantidade de dados em que um sistema tradicional de gerenciamento de banco de dados é ineficaz. É importante ressaltar que isso não se trata apenas do armazenamento dos dados, mas também do seu processamento (BOUSSOUF et al., 2018). Usar um grande volume de dados geralmente implica em modelos melhores, que então produzem análises melhores, justificando a coleta de uma grande quantidade de dados.
- **Variedade:** dados são provenientes de fontes diferentes, com formatos diferentes, sem um esquema de modelagem padronizado, como dados advindos de *logs* de computadores, dados de sensores, dados multimídia, etc. Como consequência, esses dados devem ser utilizados da forma mais transparente o possível na análise.
- **Velocidade:** dados são disponibilizados de uma forma muito rápida, e devem ser analisados da forma mais rápida o possível. Isso implica que os dados podem ser guardados e analisados até em tempo real.
- **Valor:** os dados devem ser armazenados para criar algum valor para os seus usuários, seja ele econômico, científico, social, organizacional, etc.
- **Veracidade:** os dados não possuem garantias quanto a sua qualidade, como inconsistências e falta de acurácia, porém a análise deve ser de alta qualidade de qualquer forma.

Esses V's estão relacionados com a construção de um *Data Warehouse*, sendo que também podem ser vistos como requisitos para a criação de um para um conjunto de dados caracterizado como *Big Data* (ZHANG et al., 2017). Em especial, existe um certo relacionamento com a ideia de “*NoSQL*” (“Não apenas SQL”, em inglês), em que não apenas sistemas de banco de dados relacionais são utilizados, mas também outros paradigmas são utilizados, como orientados a documentos, chave e valor, etc (BIMONTE, 2016).

2.3 *Data Warehouse*

Um Armazém de Dados ou Data Warehouse (DW) é um repositório de dados orientado por assunto, integrado, variado ou particionado em função do tempo e não volátil, que auxilia no gerenciamento do processo de tomada decisões (INMON; HACKATHORN, 1994). Essa definição pode ser dividida em:

- **Orientado por assunto:** o DW é utilizado para a análise de uma área em específico. Por exemplo, é de interesse analisar especialmente os dados da carga útil de uma forma específica.
- **Integrado:** o DW deve integrar dados vindos de múltiplas fontes de uma forma estrutura. Por exemplo, mesmo que existam duas representações diferentes para um mesmo produto, o DW deve possuir apenas uma representação. Isso requer o uso de técnicas de limpeza e integração dos dados, de modo a garantir a consistência dos dados.
- **Variado em função do tempo:** o DW deve conter, explícita ou implicitamente a perspectiva de tempo. Isso quer dizer que o DW possui dados históricos e eles podem ser consultados durante a análise. Por exemplo, pode se querer saber de dados de dias, meses ou anos atrás.
- **Não volátil:** uma vez dentro do DW, os dados não são removidos ou atualizados, sendo um requisito para a consulta de dados históricos.

Essas características diferem o *Data Warehouse* de outros sistemas de repositório, como sistemas de banco de dados, sistemas de processamento de transações e sistemas de arquivos (HAN et al., 2011).

Um DW é geralmente representado por um modelo dimensional que permite eficiência na organização dos dados e na recuperação de informações gerenciais (KIMBALL; ROSS, 2013). Neste modelo são definidos fatos, dimensões e medidas. Um fato corresponde ao assunto de negócio a ser analisado, cada dimensão é uma perspectiva de visualização do assunto de negócio e medidas são valores numéricos que quantificam o assunto de negócio. Uma das dimensões é sempre temporal para permitir a análise do assunto ao longo do tempo (SILVA, 2015).

2.4 *OLAP*

On-line Analytical Processing (OLAP) é um termo que se refere a um conjunto de ferramentas que são utilizadas para resumir, consolidar, visualizar, aplicar formu-

lações e sintetizar dados de acordo com múltiplas dimensões (CODD et al., 1998).

Um sistema OLAP permite a resposta de consultas multidimensionais usando dados armazenados no *Data Warehouse* (KIMBALL; ROSS, 2013), sendo que as características principais são (BIMONTE, 2016):

- **Consultas Online:** as consultas devem ser feitas *Online*, isto é, em tempo real para o usuário.
- **Consultas Multidimensionais:** Consultas são definidas utilizando as dimensões e medidas providas pelo *Data Warehouse*, que esperam dados de alta qualidade.
- **Representação simples:** os resultados das consultas devem ser representados utilizando tabelas e gráficos, pois os usuários finais geralmente são tomadores de decisão que precisam de visualizações relevantes.
- **Exploratórias:** as consultas são utilizadas em carácter exploratório, pois geralmente os usuários não conhecem de antemão todos os dados disponíveis para consultas.

Cada ferramenta OLAP deve manipular um novo tipo abstrato de dados (TAD), chamado de cubo de dados, utilizando estratégias específicas devido ao modo de como os dados são armazenados, sendo classificadas em (MOREIRA; LIMA, 2012):

- ***Relational OLAP (ROLAP)***: utilizam Sistemas de Gerenciamento de Banco de Dados (*Data base Management System* - DBMS) relacionais para o gerenciamento e armazenamento dos cubos de dados. Ferramentas ROLAP incluem otimizações para cada DBMS, implementação da lógica de navegação em agregações, serviços e ferramentas adicionais;
- ***Multidimensional OLAP (MOLAP)***: implementam estruturas de dados multidimensionais para armazenar cubo de dados em memória principal ou em memória externa. Não há utilização de repositórios relacionais para armazenar dados multidimensionais e a lógica de navegação já é integrada a estrutura proposta;
- ***Hybrid OLAP (HOLAP)***: combinam técnicas ROLAP e MOLAP, onde normalmente os dados detalhados são armazenados em base de dados relacionais (ROLAP), e as agregações são armazenadas em estruturas de dados multidimensionais (MOLAP).

É importante ressaltar a diferença entre OLAP e *Online Transaction Processing* (OLTP), visto que sistemas comuns de banco de dados utilizam apenas OLTP, que tem o objetivo de realizar transações e processar consultas online. Isso cobre a grande maioria das operações do dia a dia, como controle de estoque, operações bancárias, etc, servindo a diversos usuários de uma organização. Já o OLAP é utilizado por tomadores de decisão e analistas de dados, sendo voltado para decisões de mais alto nível na organização (HAN et al., 2011).

2.5 Cubo de dados

O cubo de dados originalmente foi criado como um operador relacional que gera todas as combinações possíveis de seus atributos de acordo com uma medida (GRAY et al., 1996).

A estrutura do cubo de dados permite que os dados sejam modelados e visualizados em múltiplas dimensões, e ele é caracterizado por dimensões e medidas. Uma medida é um atributo cujos valores são calculados pelo relacionamento entre as dimensões, sendo que esse é calculado utilizando funções de agregação como soma, quantidade, média, moda, mediana, etc. Uma dimensão é feita pelas entidades que compõe os nossos dados, determinando o contexto do assunto em questão (HAN et al., 2011). Uma dimensão pode ainda ser dividida em membros, que podem ter uma hierarquia, como uma divisão da dimensão tempo em dia, mês e ano.

A organização de um cubo de dados possibilita ao usuário a flexibilidade de visualização dos dados a partir de diferentes perspectivas, já que o operador gera combinações através do conceito do valor *ALL*, onde este conceito representa a agregação de todas as combinações possíveis de um conjunto de valores de atributos. Operações em cubos de dados existem a fim de materializar estas diferentes visões, permitindo busca e análise interativa dos dados armazenados (HAN et al., 2011).

Um cubo de dados é composto por células e cada célula possui valores para cada dimensão, incluindo *ALL*, e valores para as medidas. A figura 2.1 mostra um exemplo de um cubo de dados. O valor de uma medida é computado para uma determinada célula utilizando níveis de agregação inferiores para gerar os valores dos níveis de agregação superiores na estratégia *Top-down*, com a ordem inversa sendo a *Bottom-up*.

Figure 2.1 - Exemplo de um cubo de dados

Satélite	Telemetria	Valores
sat1	TM1	23
sat1	TM2	20

→


Satélite	Telemetria	Valores
sat1	TM1	23
sat1	TM2	20
sat1	ALL	43
ALL	TM1	23
ALL	TM2	20
ALL	ALL	43

SOURCE: Produção do autor.

2.5.1 Células do cubo de dados

Um cubo de dados é composto de vários subcubos, que são todos os possíveis níveis de agregação nas dimensões especificadas. Subcubos são compostos de células base e células agregadas, sendo uma célula agregada é uma célula que utiliza do valor especial *ALL* (“*”) para demonstrar que está agregando valores em uma ou mais dimensões. Uma célula base não utiliza da notação *ALL*, sendo composta do nível mais baixo de agregação (LIMA, 2009). A figura 2.2 demonstra todos os níveis de agregação de um cubo composto das dimensões A, B e C, do mais genérico (*apex*) ao mais específico(base).

Figure 2.2 - Células de agregação em um cubo de dados



SOURCE: Produção do autor.

Formalmente, supondo um cubo de dados n -dimensional, uma célula a de qualquer subcubo é definida por $a = (a_1, a_2, a_3, \dots, a_n, medidas)$. A célula é m -dimensional (de um subcubo com m dimensões), se exatamente m , com $(m \leq n)$, valores entre $(a_1, a_2, a_3, \dots, a_n)$ não são “*”. Se $m = n$, então a é uma célula base, caso contrário

($m < n$), ela é uma célula agregada.

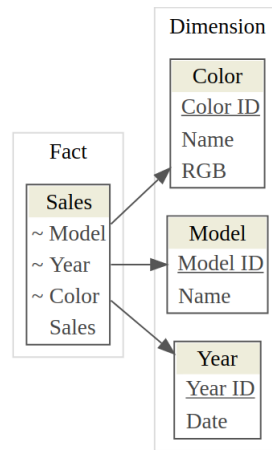
Um relacionamento de descendente-ancestral pode existir entre células. Em um cubo de dados n -dimensional, uma célula $a = (a_1, a_2, a_3, \dots, a_n, medidas_a)$ de nível i é um ancestral de uma célula $b = (b_1, b_2, b_3, \dots, b_n, medidas_b)$ de nível j , e b é um descendente de a , se e somente se $i < j$ e $1 \leq m \leq n$, onde $a_m = b_m$ sempre que $a_m \neq *$. Em particular, uma célula a é chamada de pai de uma célula b , e b de filho de a , se e somente se $j = i + 1$ e b for um descendente de a (HAN et al., 2011).

2.5.2 Modelagem dimensional

Existem três esquemas principais para a modelagem dimensional de um cubo de dados: Esquema Estrela (*Star Schema*), Esquema Floco de Neve (*Snowflake Schema*) e Constelação de Fatos (*Fact Constellation Schema*).

O esquema estrela é o mais utilizado, sendo que ele contém uma tabela central chamada de tabela de fatos, onde reside a maior parte dos dados, com um conjunto menor de tabelas, chamadas de tabelas de dimensão, para as outras dimensões. A figura 2.3 mostra um exemplo de esquema estrela.

Figure 2.3 - Esquema estrela




SOURCE: Produção do autor.

O esquema floco de neve é uma variação do esquema estrela, onde algumas dimensões são normalizadas, dividindo os dados das tabelas de dimensão em outras tabelas. Isso possui vantagens de eliminar redundâncias nas tabelas de dimensão, porém cria

problemas durante a execução de consultas, visto que é necessário realizar operações de *join* com as novas tabelas. A figura 2.4 mostra um exemplo de esquema floco de neve.

Figure 2.4 - Esquema floco de neve



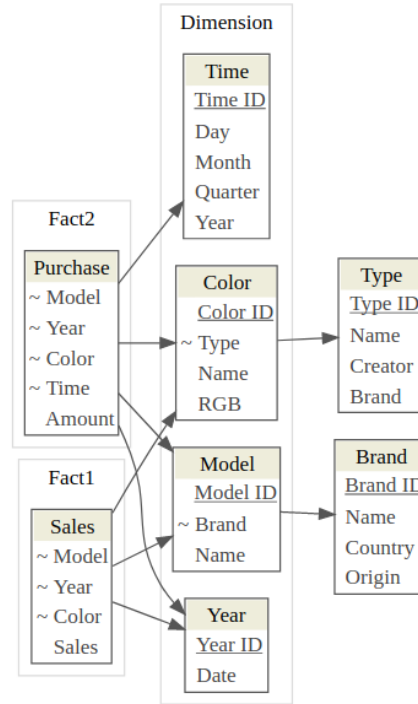
SOURCE: Produção do autor.

O esquema constelação de fatos utiliza de múltiplas tabelas de fato, como se fossem várias tabelas no esquema estrela que compartilham tabelas de dimensão. Isso leva ao seu nome, como um conjunto de estrelas. A figura 2.5 mostra um exemplo de constelação de fatos.

2.5.3 Hierarquias de conceito

Uma hierarquia de conceitos é utilizada para definir uma sequência de mapeamento entre um conjunto de conceitos de baixo nível para um conjunto de conceitos de alto nível, mais gerais. É um estilo de agrupamento e discretização, pois agrupa os valores de modo a reduzir a cardinalidade de uma dimensão (HAN et al., 2011). Elas ajudam a tornar a análise mais fácil de ser entendida, pois as operações traduzem os dados de baixo nível em uma representação que é mais fácil para o usuário final, assim facilitando a execução das consultas e o seu subsequente uso.

Figure 2.5 - Esquema constelação de fatos



SOURCE: Produção do autor.

2.5.4 Medidas

Cada célula de um cubo é definida como um par $\langle (d_1, d_2, \dots, d_n), medidas \rangle$, onde (d_1, d_2, \dots, d_n) representam as combinações possíveis de valores de atributos sobre as dimensões. Uma medida é calculada para uma certa célula agregando os dados correspondentes a combinação de dimensões e valores (HAN et al., 2011). Medidas podem ser classificadas em três tipos: distributiva, algébrica e holística.

Uma medida distributiva é uma medida cujo cálculo pode ser particionado e depois combinado, e o resultado seria o mesmo se o cálculo fosse executado em todo o conjunto de dados. Por exemplo, a função de soma é distributiva: dividindo os dados N em conjuntos n , e fazendo a soma de cada conjunto n , teremos o mesmo resultado que se a fosse feita diretamente sobre N .

Uma medida algébrica é uma medida cujo cálculo pode ser feito sobre duas ou mais medidas distributivas. Por exemplo, uma medida de média pode ser calculada com a divisão da medida *soma* pela a medida *contagem*, que são ambas distributivas.

Uma medida é holística se não existe uma medida algébrica com M argumentos que caracterize a computação. Isso quer dizer que a computação não pode ser particionada, com valores exatos obtidos apenas se a medida for aplicada em todos os dados. Alguns exemplos são as medidas de moda, desvio padrão e mediana (HAN et al., 2011).

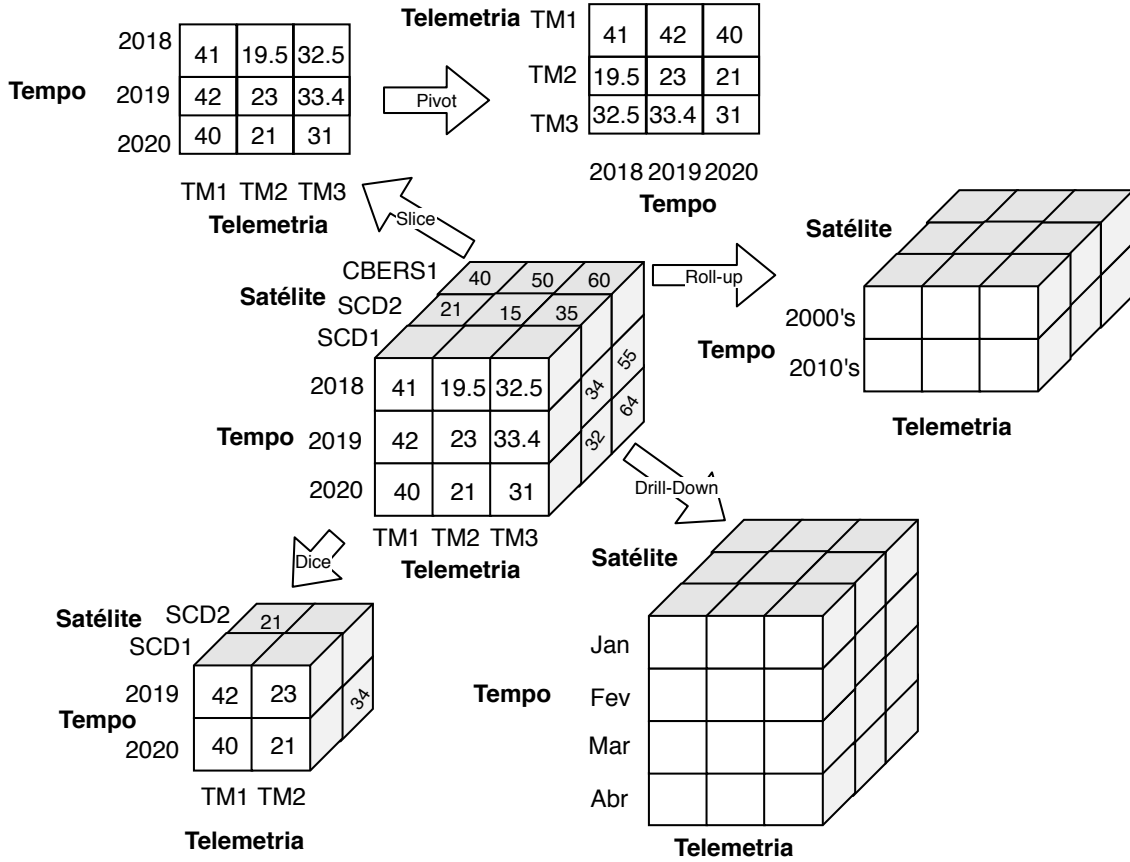
2.5.5 Operações OLAP

Para realizar consultas no *Data Warehouse*, é necessário utilizar de algumas operações sobre o cubo de dados para obter os resultados adequados. Essas consultas também devem conseguir passar na hierarquia de conceitos de cada dimensão, bem como seguir o modelo dimensional do cubo definido, para conseguir oferecer uma interface amigável com o usuário para análise interativa (HAN et al., 2011). Algumas operações estão exemplificados na figura 2.6, porém elas geralmente são:

- *Roll-up*: realiza agregação no cubo de dados, seja navegando na hierarquia de conceitos de nível específico para um mais genérico, ou reduzindo uma dimensão.
- *Drill-down*: o inverso da operação *roll-up*, navega na hierarquia de conceitos do nível mais genérico para o nível mais específico, ou adiciona dimensões ao cubo atual. Essa operação visa aumentar o nível de detalhes dos dados.
- *Slice*: ou “fatiamento”, realiza uma seleção em uma dimensão do cubo, resultando em um subcubo.
- *Dice*: define um subcubo realizando uma seleção (*slice*) em duas ou mais dimensões.
- *Pivot*: também chamada de rotação, permite mudar a posição das dimensões na visualização, portanto alterando linhas por colunas e vice-versa.

Dependendo do sistema OLAP, é possível que outras operações sejam possíveis, como *drill-across* que passa por mais do que uma tabela de fatos, e *drill-through* que permite executar consultas direto na representação em baixo nível do cubo (HAN et al., 2011).

Figure 2.6 - Operações *OLAP* em um cubo de dados



SOURCE: Produção do autor.

2.5.6 Computação do cubo de dados

A computação do cubo de dados é uma tarefa essencial, pois a pré-computação de todo ou parte de um cubo de dados pode aumentar significativamente o desempenho do DW. Porém, essa tarefa possui complexidade exponencial em relação ao número de dimensões, sendo chamada de materialização, com a materialização completa exigindo uma grande quantidade de células, e portanto um elevado consumo de memória e tempo (HAN et al., 2011).

O cálculo original da computação do cubo de dados foi proposta por (GRAY et al., 1996), sendo: dada uma relação de entrada R com tuplas de tamanho n , o número de subcubos que podem ser gerados é 2^n , onde n é o número de dimensões do cubo. Por exemplo, supondo um cubo com três dimensões *Satélite*, *Telemetria*, *Valor*, teremos $2^3 = 8$ subcu-

bos possíveis: $\{(satélite, telemetria, valor), (satélite, valor), (satélite, telemetria), (telemetria, valor), (telemetria), (valor), (satélite), ()\}$, com $()$ denotando o agrupamento vazio (célula base, as dimensões não estão agrupadas).

Porém, na prática, as dimensões podem possuir hierarquias de conceito associadas, como para a dimensão tempo: “dia<mês<trimestre<semestre<ano”. Para um cubo com n dimensões com múltiplas hierarquias de conceito, o número total de subcubos é apresentado na equação 2.1.

$$subcubos = \prod_{i=1}^n (L_i + 1) \quad (2.1)$$

Onde L_i é o número de níveis de conceito da dimensão i . É necessário adicionar um a equação 2.1 para denotar o nível virtual *ALL*. O tamanho de cada subcubo também depende da cardinalidade de cada dimensão, isto é, o número de valores distintos. Enquanto o número de dimensões, hierarquias de conceito e cardinalidade do cubo aumenta, também aumentam os seus requisitos de espaço de forma exponencial, sendo conhecida como a **maldição de dimensionalidade** na computação do cubo (HAN et al., 2011).

Para conseguir responder as consultas de maneira apropriada, é necessário escolher um método para a computação dos subcubos: a não materialização, a materialização completa e a materialização parcial.

Na não materialização, os subcubos agregados não são pré-computados, assim as agregações são computadas imediatamente, que podem ser extremamente lentas, porém tem o menor consumo de memória.

A materialização completa computa todos as agregações possíveis do cubo, gerando um cubo de dados completo. Esse método gera os melhores tempos de resposta, pois as agregações já foram computadas, porém necessita de uma grande quantidade de espaço de memória.

A materialização parcial computa apenas um subconjunto selecionado de subcubos, sendo que existem diversas técnicas diferentes de seleção dos subcubos que serão computados. Uma delas é computar todos os subcubos que contém apenas células que satisfazem um dado critério, especificado pelo usuário. Esses cubos são chamados de *iceberg* (BEYER; RAMAKRISHNAN, 1999).

Outra técnica é computar cubos pequenos, geralmente entre 3 e 5 dimensões, para formar cubos completos. Para responder consultas com mais dimensões, as combinações entre os subcubos pequenos são agregadas. Esta técnica é chamada de *shell fragment*, e o cubo é chamado de *cube shell* (LI et al., 2004).

Um cubo de dados onde as células com medidas idênticas são encapsuladas em uma única abstração, chamada de célula fechada (*closed cell*) é chamado de cubo fechado, ou cubo quociente. Esta técnica foi apresentada com o cubo fechado (*closed cube*) (Dong Xin et al., 2006) e com o cubo quociente (*quotient cube*) (LAKSHMANAN et al., 2002).

A escolha da materialização parcial depende do equilíbrio necessário entre tempo de resposta e espaço de armazenamento. Porém, a computação do cubo completo continua sendo relevante, sendo que os avanços na computação dos cubos parciais são geralmente adotados na computação do cubo completo. Existe ainda o problema de atualização do cubo, pois cada atualização pode causar uma recomputação parcial ou completa do cubo para manter as medidas corretas.

A partir de um cubo base, a computação do cubo de dados pode utilizar a estratégia *Top-down* ou *Bottom-up* para a geração dos subcubos remanescentes (HAN et al., 2011).

A figura 2.7 mostra a geração de um cubo de dados de quatro dimensões pela estratégia *Top-down*. Sendo ABCD um cubo base, os subcubos de três dimensões são: ABC, ABD, ACD e BCD; que podem utilizar os resultados do cubo base para serem computados.





Figure 2.7 - Computação de cubo de dados através da estratégia *Top-Down*

SOURCE: (SILVA, 2015).

Os resultados da computação do subcubo ACD podem ser utilizados para computar AD, que consequentemente podem ser utilizados para computar A. Essa computação compartilhada permite que a estratégia *Top-down* compute agregações em múltiplas dimensões. Os valores agregados intermediários podem ser reutilizados para a computação de subcubos descendentes sucessivos.

A Figura 2.8 mostra a geração de um cubo de dados de 4 dimensões por meio da estratégia *Bottom-up*. Subcubos de poucas dimensões tornam-se pais de subcubos com mais dimensões. Infelizmente, a computação compartilhada, utilizada na estratégia *Top-down*, não pode ser aplicada quando utilizada a estratégia *Bottom-up*, então cada subcubo descendente necessita ser computado do início.

Figure 2.8 - Computação de cubo de dados através da estratégia *Bottom-up*



SOURCE: (SILVA, 2015).

3 RELATED WORKS

In this section the related works will be presented, and they can be divided into two sections: the Big Data solutions from other operators, and the algorithms for the construction of data cubes with high cardinalities.

3.1 Operations Data

Table 3.1 shows the common data types used and generated by satellite operators, their origin and the common format for communication. These data are either available to the satellite, or to the satellite operators in some way.

Table 3.1 - Operations Data

Data Type	Source	Format
On-Board sensors	Satellite Equipment	Tables, CSV
Computer Logs	On-Board computer	Text (<i>Logs</i>)
Multimedia	Camera	MP4, JPG, RAW
Orbital Parameters	Operations and Tracking	TLE, text, tables
Associated documentation	Operators, Engineering	Text (Word, Excel, PDF)
Space Weather	Space or ground based information	Text, tables, warnings
Situational Awareness	Radars, US-STRACOM, etc	CDM, text, tables, warnings

SOURCE: Adapted from (ZHANG et al., 2017)

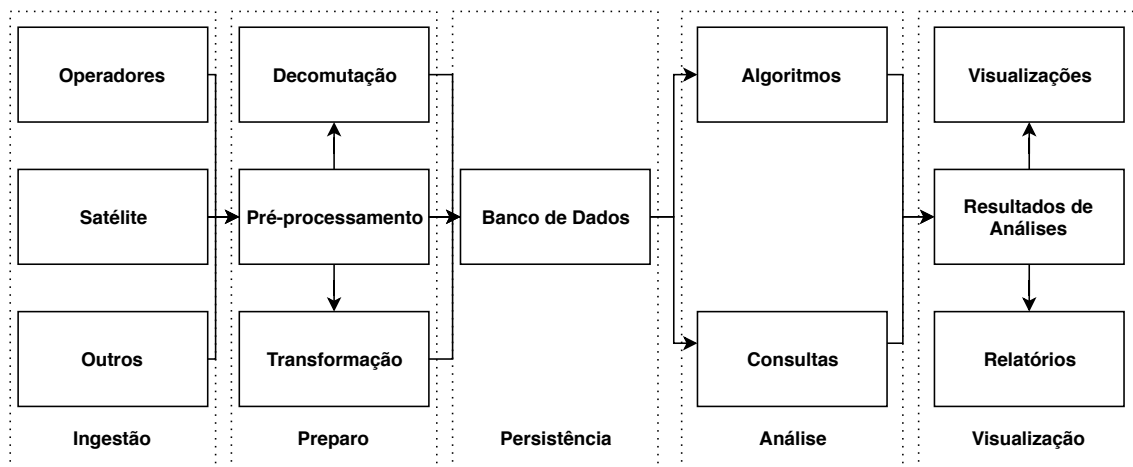
For this work, only the data from the on-board sensors will be considered, as the other data in this table can be considered for a larger data management effort by the operator organization, however they are out of scope.

3.1.1 Data Flow

Baseado nos trabalhos correlatos e nos dados levantados, a figura 3.1 demonstra o fluxo de dados esperado de uma arquitetura de *Big Data* para a operação de satélites.

Este fluxo está separado em cinco etapas que vão desde a origem dos dados até o seu resultado de análise, e este trabalho visa apenas mapear qual seria esse fluxo baseado nos trabalhos correlatos. Cada uma das etapas está detalhada a seguir:

Figure 3.1 - Fluxo de dados em uma arquitetura de *Big Data*



SOURCE: Adaptado de (ZHANG et al., 2017)

- **Ingestão:** onde os dados serão coletados na sua fonte (satélites, sensores no solo, outras fontes, etc). Essa etapa trata de **onde** estão os dados e **como** coletá-los, bem como **quais** são os dados importantes de serem coletados. A “fonte” aqui pode ser um serviço de terceiros, dentro da própria instituição ou disponível de outra forma.
- **Preparo:** os dados relevantes são selecionados, e transformações são realizadas para inserir os mesmos na base de dados. Essa etapa trata do formato específico dos dados, realizando operações de limpeza, verificação da qualidade e da relevância para a análise, entre outras. O seu objetivo é garantir que os dados tem qualidade, relevância, e estão no formato adequado para a base de dados.
- **Persistência:** após o devido processamento, os dados de alta qualidade são guardados em uma base de dados, de onde ficarão disponíveis para a análise. Nessa etapa um banco de dados é utilizado, tratando apenas em como esses dados estão guardados e como eles serão disponibilizados para as consultas e execução de algoritmos.
- **Análise:** nesta etapa são executadas as consultas e os algoritmos de interesse para a análise. Podem ser desde consultas simples (“qual era o valor

da telemetria X durante a passagem Y?”), a execução de algoritmos complexos (“preveja os valores da telemetria X para a próxima passagem”).

- **Visualização:** os resultados das consultas e algoritmos são visualizados. Podem conter desde gráficos simples, como um histograma de uma telemetria, a relatórios complexos de um subsistema/satélite, bem como resultados de algoritmos.

Os trabalhos de (ZHANG et al., 2017), (MATEIK et al., 2017) e (BOUSSOUF et al., 2018) definem esse processo mais claramente dentre os trabalhos apresentados.

3.2 Análise de dados em outros operadores de satélite

A tabela 3.2 mostra uma revisão feita em artigos recentes sobre os operadores de satélite e quais tecnologias eles estão utilizando para atingir objetivos semelhantes, principalmente com o uso de *Big Data*.

Os objetivos em comum desses trabalhos são facilitar as atividades dos operadores por meio de algoritmos de detecção de anomalias e de verificação dos limites nos valores das telemetrias. Alguns dos operadores dessa lista estão responsáveis pela operação de constelações de satélites complexos, como constelações de sensoriamento remoto, que faz necessário um certo nível de automação ou a operação contínua teria um custo inviável.

Nesses trabalhos, o uso dessas tecnologias é apenas para os operadores de satélite, pois em nenhum desses trabalhos eles estão na mesma estrutura de ingestão dos dados da carga útil, mesmo utilizando as mesmas tecnologias, como demonstrado em (MATEIK et al., 2017) e (ADAMSKI, 2016).

Alguns desses trabalhos não utilizam de estruturas completas que seguem um fluxo de dados, como é o caso de (FERNÁNDEZ et al., 2017) e (TROLLOPE et al., 2018) que utilizam de *scripts* feitos de forma *ad-hoc*, não mostrando uma visão da arquitetura completa do fluxo de dados e apenas a ferramenta utilizada para análise pontual.

O trabalho de (YVERNES, 2018) utiliza de estratégias OLAP e do cubo de dados, tendo utilizado uma modelagem dimensional para a operação de uma constelação de satélites, porém esse trabalho menciona apenas em alto nível a modelagem utilizada, e menciona que o trabalho foi somente na parte da modelagem dimensional e integração dos dados utilizando ferramentas já existentes.

Table 3.2 - Operadores de Satélite e Arquiteturas de Big Data

Referência	Operador	Ferramenta	Tecnologias
(ADAMSKI, 2016)	L3 (EUA)	InControl	Hadoop, Spark, HBase, MongoDB, Cassandra, Amazon AWS
(BOUSSOUF et al., 2018)	Airbus	Dynaworks	Hadoop, Spark, HDFS, HBase, PARQUET, HIVE
(SCHULSTER et al., 2018)	EUMETSAT	CHART	MATLAB, MySQL, Oracle
(ZHANG et al., 2017)	SISSET (China)	-	Hadoop, HDFS, PostgreSQL, MongoDB, Logstash, Kibana, ElasticSearch, Kafka, MapReduce
(YVERNES, 2018)	Telespazio France	PDGS	OLAP (DataCube), Saiku, Pentaho, Jaspersoft OLAP
(DISCHNER et al., 2016)	SwRI + NOAA	CYGNSS MOC	SFTP, -
(EDWARDS, 2018)	EUMETSAT	MASIF	FTP, RESTful service, JMS Message Queue, PostgreSQL
(EVANS et al., 2016)	S.A.T.E + ESA/ESOC	-	Java, CSV
(FEN et al., 2016)	CSMT (China)	-	não menciona as tecnologias
(TROLLOPE et al., 2018)	EUMETSAT	CHART	algoritmos ad-hoc, estudo de caso
(GILLES, 2016)	L-3	InControl	Amazon EC2, LXC, Nagios
(HENNION, 2018)	Thales Alenia	AGYR	Logstash, Kafka, InfluxDB, ElasticSearch, Kibana, Grafana
(MATEIK et al., 2017)	Stinger, NASA	-	Logstash, ElasticSearch, Kibana, HDF5, CSV, R, Python, AWS, Excel
(FERNÁNDEZ et al., 2017)	NASA	MARTE	R, CSV, ad-hoc

SOURCE: Produção do autor.

3.2.1 Análise de dados no INPE

O INPE já realiza análise de dados em outros departamentos, inclusive sobre as telemetrias de satélite. Os operadores devem monitorar os valores das telemetrias e informar a engenharia caso apareça algum problema que não pôde ser corrigido (TOMINAGA et al., 2017). Um exemplo está no trabalho (MAGALHÃES, 2012), feito sobre uma falha no satélite CBERS-2, onde o modelo proposto visa melhorar o conhecimento sobre avalanche térmica nas baterias para impedir que isso aconteça novamente em outros satélites. A motivação principal dos trabalhos da tabela 3.2 era a detecção de anomalias, que teve alguns algoritmos estudados em (AZEVEDO et al., 2011).

Outros setores, utilizam a análise de dados vindos da carga útil do satélite ou de agentes externos ao INPE, como dados de sensoriamento remoto, cuja análise não é trivial e também estão classificados como *Big Data*. Monteiro (2017) utilizam de conceitos de Big Data para análise de trajetórias de objetos; Ramos et al. (2016) demonstram o uso de softwares como o Hadoop para a análise de dados do clima espacial, com uma arquitetura relacionada as arquiteturas revisadas na seção anterior; e Simões et al. (2018) mostra uma arquitetura que utiliza de cubo de dados para a análise de séries temporais no sensoriamento remoto.

3.3 Computação do cubo de dados

A computação seletiva do cubo de dados possui muitos algoritmos diferentes implementados, porém eles possuem dificuldades no trato de dados com muitas dimensões e no uso limitado da memória (HAN et al., 2011).

O *Frag-Cubing* (LI et al., 2004) apresenta o conceito de *cube shells*, onde subcubos com poucas dimensões (de 3 a 5 neste exemplo) são calculados utilizando de índices invertidos, que funcionam apenas utilizando memória principal. A ideia principal é decompor o cubo original em fragmentos que podem ser reunidos eficientemente para responder uma consulta multidimensional.

Precursor para o computação distribuída do cubo, (DOKA et al., 2011) apresenta o *Brown Dwarf*, um sistema *Peer-to-Peer* que permite atualização das células, desenhado para diminuir a redundância em cubos distribuídos.

O *PopUp-Cubing* é apresentado em (HEINE; ROHDE, 2017), que utiliza de icebergs para lidar com dados em formato de *stream*, obtendo resultados superiores ao FTL e *Star-Cubing*. Este trabalho é de interesse especial por utilizar de dados de *stream*,

que permitiriam resultados parecidos com tempo real, que são mais parecidos com os dados disponíveis para a operação de satélites, porém este cenário não será abordado neste trabalho.

Com foco em *Big Data* e utilizando como base o esquema *MapReduce*, (WANG et al., 2013) apresenta o algoritmo *HaCube* para computação do cubo em paralelo. Este trabalho apresenta um balanço entre computação do cubo em paralelo por vários nós de *MapReduce*, que permite algumas atualizações e computação incremental de medidas. Devido a própria natureza distribuída, ele precisa de mecanismos de tolerância a falha, e também os testes foram executados com no máximo apenas 5 dimensões, porém com até 2,4 bilhões de tuplas. Ainda na linha do *MapReduce*, (YANG; HAN, 2017) demonstra a computação de medidas holísticas apresentando o *Multi-RegionCube*, porém realizando menos testes que o *HaCube*.

Em (ZHAO et al., 2018) é apresentado o *Closed Frag-Shells Cubing*, que utiliza de uma combinação da abordagem de cubos fechados com a abordagem *Shell fragments*, obtendo resultados melhores que a aplicação de cada uma delas separadamente. Essa abordagem utiliza de índices *bitmap* e índices invertidos, sendo que lidam com dados altamente dimensionais e sem uma hierarquia de forma similar ao necessário neste trabalho.

qCube (SILVA et al., 2013) estende a abordagem *Frag-Cubing* para permitir consultas sobre intervalos de valor, estendendo os operadores de consultas clássicas em cubo de dados além do operador de igualdade.

HFrag (SILVA et al., 2015) apresenta o uso de memória externa na computação dos índices invertidos, utilizando de um sistema híbrido de memória para armazenar as partições do cubo tanto na memória principal quanto na secundária, com os valores mais frequentes sendo armazenados na memória principal e os valores menos frequentes na memória secundária.

A abordagem *Hybrid Inverted Cubing* (HIC) (SILVA et al., 2016) estende a abordagem *HFrag* com o parâmetro de frequência acumulada crítica, obtendo resultados melhores do que este nas mesmas consultas.

Destes trabalhos, o *Frag-Cubing* continua sendo um algoritmo robusto para a computação do cubo, com suas técnicas de índice invertido sendo utilizadas e ainda obtendo resultados adequados. Porém, Li et al. (2004) ilustram o impacto exponencial no consumo de memória nas diferentes abordagens de computação de cubos de

dados usando apenas 12 dimensões, sendo que há uma saturação quando cubos com 20, 50 ou 100 dimensões são computados utilizando abordagens de cubos completos, cubos DWARF, MCG, cubos fechados ou quocientes (SILVA, 2015).

3.3.1 Frag-Cubing

O *Frag-Cubing* (LI et al., 2004) apresenta o conceito de inversão de tupla. Cada tupla invertida iT tem um valor de atributo, uma lista de identificadores da tupla (TIDs) e um conjunto de valores de medida. Por exemplo, consideremos quatro tuplas: $t_1 = (tid_1, a_1, b_2, c_2, m_1)$, $t_2 = (tid_2, a_1, b_3, c_3, m_2)$, $t_3 = (tid_3, a_1, b_4, c_4, m_3)$, e $t_4 = (tid_4, a_1, b_4, c_1, m_4)$. Estas quatro tuplas geram oito tuplas invertidas: $iTa_1, iTb_2, iTb_3, iTb_4, iTc_1, iTc_2, iTc_3$ e iTc_4 , demonstradas na figura 3.2.

Para cada valor de atributo é construído uma lista de ocorrências, assim para a_1 temos $iTa_1 = (a_1, tid_1, tid_2, tid_3, tid_4, m_1, m_2, m_3, m_4)$ onde o valor de atributo a_1 está associado aos TIDs: tid_1, tid_2, tid_3 , e tid_4 . O identificador de tupla tid_1 tem o valor de medida m_1 , tid_2 tem o valor de medida m_2 , tid_3 tem o valor de medida m_3 , e tid_4 possui o valor de medida m_4 . A consulta $q = (a_1, b_4, COUNT)$ pode ser respondida por $iTa_1 \cap iTb_4 = (a_1 b_4, tid_3, tid_4, COUNT(m_3, m_4))$. Em q , $iTa_1 \cap iTb_4$ indica os TIDs comuns em iTa_1 e iTb_4 .

Figure 3.2 - Exemplo de uma tabela dimensional e a respectiva lista de índices invertidos

TID	A	B	C	m
tid1	a1	b2	c2	m1
tid2	a1	b3	c3	m2
tid3	a1	b4	c4	m3
tid4	a1	b4	c1	m4

Valor	Lista de TIDs	Medidas
a1	tid1, tid2, tid3, tid4	m1, m2, m3, m4
b2	tid1	m1
b3	tid2	m2
b4	tid3, tid4	m3, m4
c1	tid4	m4
c2	tid1	m1
c3	tid2	m2
c4	tid3	m3

SOURCE: Produção do autor.

A complexidade da interseção é proporcional ao número de ocorrências de um valor de atributo, mais precisamente é igual ao tamanho da menor lista. Neste exemplo, iTb_2 com um TID é a menor lista. O número de TIDs associado a cada valor de atributo pode ser enorme, assim relações com dimensões de baixa cardinalidade e elevado número de tuplas necessitam de alta capacidade de processamento. Listas de TIDs pequenas permitem que consultas sejam respondidas rapidamente, portanto relações com baixo *skew* e alta cardinalidade são mais adequadas de serem computadas pela abordagem *Frag-Cubing*.

Skew pode ser definido como o grau de uniformidade dos valores de atributos numa relação, sendo que *skew* zero indica relação com valores de atributos uniformemente distribuídos, e quanto maior o *skew* menos uniformemente distribuída a relação se encontra.

4 Query Partition

In this chapter, an algorithm for aggregating the satellite telemetries into relationship groups is presented, which is then used to selected useful queries by a satellite operator. These queries are then compared with the Frag-Cubing algorithm: one set is called High-Dimensional, in which the queries are executed on the full data dimensionality; and the other is Low-Dimensional, in which the input data for the data cube algorithm is made of only the dimensions that the query will execute. The aim of this work is then to see if the query response time and memory consumption can be improved by pre-filtering the data that will be queried with just the dimensions related to that query.

4.1 Algorithm

The objective of this algorithm is to easily classify the rate of change between groups of telemetries, as from previous data science work conducted on the telemetry data, just by identifying whether a group of telemetries change on a similar rate, it is possible to find a relationship between them. The algorithm is separated into two parts: the groups generation and the strength calculation.

4.1.1 Aggregation Generator

The algorithm works by creating telemetry groups with all possible dimensional combinations, considering that each telemetry is treated as a dimension. The combination of a given set of \mathbf{n} elements taken \mathbf{k} at a time is given by formula 4.1.

$$C_k^n = \binom{n}{k} \quad (4.1)$$

Since the number of telemetries is usually on the order of hundreds to thousands, it's best to limit the algorithm to combinations taken from 2 to 5 at a time. This is equivalent of computing a all subcubes with those dimensions. That gives us the following number of combinations, with \mathbf{kmax} being the biggest k that we want, on formula 4.2.

$$\sum_{2 \leq k \leq n}^{kmax} \binom{n}{k} = 2^{n-2} \quad (4.2)$$

Each of these combinations is generated from a vector of n telemetry names that

we're interested. For each of the generated combinations, we then execute aggregation measures:

- Group the available telemetry readings by the combination groups
 - for the combination “TM001”, “TM002”, group the table by “TM001” and “TM002”
- Each aggregate is counted for frequency that the values appear, called *count* henceforth
 - TM001 = [”01“] && TM002 = [‘02’] -> count = 25
- For each of the telemetries used, compute the cardinality of the telemetry, called C_t for telemetry t
 - TM001 = [‘01’, ‘02’, ‘03’], then it’ll have cardinality 3
- Compute descriptive statistics over all the values of *count*
 - Number of aggregates (length of the vector)
 - Mean
 - Median
 - Standard deviation

4.1.2 Relationship Strength Calculation

We can then use the descriptive statistics to calculate the strength of the relationship between the telemetries. This involves the use of conditionals and some parameters from the algorithm.

The initial condition is that if the cardinality of any telemetry is 1, it means that it didn’t change in the time period, hence any aggregate with $C_t = 1$ will be marked with *NONE* on relationship. If the number of groups is 1 it also means that no changes were observed in the period, so we can’t infer any relationships from the data, and the relationship is marked *NONE*.

If that condition passes, then we compute some values to help with classifying the other cases:

The biggest possible number of groups expected is the product of the sequence of cardinalities, called maxc is given by equation 4.3.

$$maxc = \prod_t C_t = C_1 * \dots * C_t \quad (4.3)$$

The biggest cardinality in the combination, to us the *minimum* possible value for the number of groups, called *minc* on equation 4.4.

$$minc = \max(C_1, \dots, C_t) \quad (4.4)$$

The proportion of the number of groups by the maximum cardinality, called *cratio* on equation 4.5.

$$cratio = \frac{numgroups}{maxc} \quad (4.5)$$

The absolute cardinality difference, as it is more representative of the discrepancy between bigger cardinalities, called *absdiff* on equation 4.6.

$$absdiff = cratio - \frac{minc}{maxc} \quad (4.6)$$

The coefficient of variation, from the standard deviation σ and the mean μ , called *CV*, is used to check the variability of the number of groups inside an aggregate on equation 4.7.

$$CV = \frac{\sigma}{\mu} \quad (4.7)$$

After all of those values, we are left with the choice of some parameters: the absolute cardinality ratio cutoff; the CV minimum and maximum cutoff and the CV minimum cutoff for the medium case.

Each of these parameters is necessary to characterize the distribution of each combination. A high number of groups does not tells us much about it's distribution: we need more statistics to know if the groups are evenly spread or if they are focused on few values. Knowing that is essential to be able to distinguish the strength of the relationships.

So, the cardinality ratio cutoff is the first: it tells us how the cardinalities change in relation to each other. The number *cratio* will be closer to 1 if there's a relationship of 1 to 1 for each telemetry. This means that every time that one telemetry changes, the others changes too.

In contrast, a number closer to 0 means that the telemetries have very little variability, and that they're using the minimum expected cardinality. This means that the number of groups is closer to *minc*, and the variability is low.

The CV is then used to peer into the distribution of aggregates, by telling us if they're focused on few values or more spread evenly. A value close to, or bigger than, one means that the data are very spread, and thus might have a strong relationship, as that means that they tend to change together. A value closer to the CV minimum cutoff has data with low variability, which means that they're probably clustered together on few values. If it's within the absolute cardinality variability cutoff, then this value also denotes a strong relationship. If the value is within both cutoffs, then it's neither very clustered nor much variable, so we adopt a medium strength relationship.

From each of these paths, we have a single strength relationship, however the relative adoption of the relationship strength calculation is subjective, as the cutoff points need to be manually defined. With this algorithm, some 2x2 and 3x3 relationships were generated by grid searching all possible relationships and then showed to a satellite operator for evaluation.

4.2 Queries

With the satellite operator help, some sample queries that are frequent to the satellite operation procedures were filtered, not only related by their relationship but how useful the operator found them for their activities. The related telemetries are summarized in [Table 4.1](#), with their identification, brief description and the calculated cardinality from the historic database. In this table, the cardinality of each telemetry is defined as the number of unique values that the telemetry can take.

4.2.1 Q1

Question: are the batteries being charged or discharged?

The related telemetries are: TM072 and TM081 are each of the satellite's battery thermistor readings, TM077 and TM078 are charge regulator telemetries for each

Table 4.1 - Telemetries overview

ID	Description	Cardinality
TM001	Payload receiver voltage	149
TM002	Payload RF output power	175
TM003	Magnetometer 1, Y axis	251
TM004	Magnetometer 1, -X axis	251
TM005	Magnetometer 1, Z axis	251
TM006	Magnetometer 2, Y axis	251
TM072	Battery Temperature 1	251
TM075	Solar Panels Current	251
TM077	Battery Charge Regulator 1	2
TM078	Battery Charge Regulator 2	2
TM081	Battery Temperature 2	251
TM082	Battery Discharge Regulator 1	2
TM083	Battery Discharge Regulator 2	2
TM130	Solar sensor temperature 1	233
TM131	Solar sensor temperature 2	233

of the batteries, and TM080 and TM081 are discharge regulator indicators for each battery. The regulator telemetries simply indicate whether each battery is being charged or discharged as seen by the OBC, and take the form of “ON” and “OFF” values, while the thermistor telemetries indicate the thermal behavior of each battery.

This seems trivial at first glance: TMs 77, 78, 80 and 81 already display this information as each batteries’ charge regulators, directly as collected by the OBC. However, in the case of this satellite, the thermal behavior of the batteries is important to verify whether the batteries are actually being charged or not. Furthermore, an overloading of one of the batteries might cause the relationship between the regulators to change and not show an accurate picture of what is happening, relating the query to anomaly discovery.

4.2.2 Q2

Question: **what is the current satellite orientation?**

The three telemetries are related to the magnetometer measurements, each (3, 4, 5) being of one axis (Y, X, Z) and with 300 mGauss precision.

This query has a simple objective of showcasing one of the most frequent operator activities: determining the satellite attitude. The strongest magnetic field will be

the Earth's, and for this satellite, it has the express goal of deciding whether the satellite's antennas are still pointed in the correct direction to earth, and to verify the satellite's rotation rate. This satellite is stabilized by spin, and so verifying the speed and direction of spin is crucial for operations.

4.2.3 Q3

This question is meant as a comparative between the previous query: **is there any difference between the magnetometer readings in the satellite?**

As mentioned, TM003 is related to the magnetometer in the Y axis at 300 mGauss, and TM006 is just a redundant instrument with 600 mGauss precision for the same axis. This is meant to both create a redundancy in the instrument readings, as there are two instruments to measure the attitude that can be directly compared to see if there is any discrepancy in the sensors.

4.2.4 Q4

This question means to probe the data collection antenna: **is the payload antenna working as expected?**

These telemetries are related to the primary payload, the Data Collection Payload. TM001 measures the voltage of the data collection antenna, while TM002 measures the output transmission gain of the antenna. This subsystem works by retransmitting the data from data collection platforms on various places of the earth to INPE's Mission Exploitation Center, and thus is relatively simpler to maintain. This query aims to see if the antenna is working as it should: the output gain is generally very stable, and the voltage is meant to just monitor if the antenna electronics are working.

4.2.5 Q5

Question: **are there any discrepancies between the measured currents and the solar panels temperatures?**

Telemetries 130 and 131 are thermistor readings for the solar panels, 75 measures the total output current, and 76 measures the shunt current for the solar charging system. The shunt aims to regulate the current that is measured in TM075, that is the main output of the solar panels, and used to charge the batteries and to power the satellite. If the temperature telemetries (130 and 131) have readings that are

too hot or too cold, the solar panels might fail and not provide the necessary power to the satellite anymore, which would be catastrophic failure, as the satellite would not be able to recharge its batteries and would stop working.

4.2.6 Summary

Table 4.2 has an overview of the queries presented, with the query identification, the telemetries that are queried and the product of the cardinalities involved.

Table 4.2 - Queries overview

ID	Telemetries	Product of cardinalities
Q1	TM072, TM081, TM077, TM078, TM082, TM083	983.920
Q2	TM003, TM004, TM005	15.813.251
Q3	TM003, TM006	63.001
Q4	TM001, TM002	26.075
Q5	TM130, TM131, TM075	14.397.360

4.3 Experimental Validation

To validate whether the pre-selection effectively reduces query memory consumption and response times, it is needed to test it against the Frag-Cubing algorithm. This section details how this selection was performed, the used algorithms and presents a simple overview of the results.

4.3.1 Dataset and Method

The Frag-Cubing algorithm used the Illimine project implementation ([ILLIMINE, 2004](#)) that was coded in C++ and compiled on a Linux Kernel 5.0.0-29 machine, with gcc 7.4.0. Some adaptations were made to the original code to allow for better output formatting, however these were minimal format changes and didn't impact on the performance or changed how the algorithm works. All of the experiments were executed on an Intel(R) Core(TM) i7-8550U CPU @ 1.80 GHz, with 16 GB of DDR4 @ 2400 MHz system memory and on an Adata XPG SX8200 Pro Solid State Drive using PCIe Gen 3x4 interface.

The experiments were designed to measure:

- Base cube main memory;
- Runtime to build the base cube representation;
- Query response time;
- Query memory increase, which measures how much memory was needed to answer the query beyond what was used by the base cube.

As a notational convention, we use \mathcal{D} to denote the number of dimensions, \mathcal{C} the cardinality of each dimension, \mathcal{T} the number of tuples in the database, \mathcal{F} the size of the shell fragment, \mathcal{I} the number of instantiated dimensions, \mathcal{Q} the number of inquired dimensions, and \mathcal{S} the skew or zipf of the data. Minimum support level is 1, as well as $\mathcal{F} = 1$ for all experiments.

Each test was executed 5 times, with the average value of the five runs being taken. Additionally, before each test a baseline with no performed queries was executed, just computing the time to cube: how long, and using how much memory, it takes for the algorithm to compute the initial cube. This is meant to ease the comparison of the results.

The central idea of this experiment is to partition the input data with the dimensions with the expected dimensions used in a query, to see if that is a better or worse cube construction strategy. To achieve that, the 4 year of data resulted in to 24 M (2.4×10^7) tuples over the satellite’s 135 telemetries, saved in a relational database. Those were separated into files for each query and each data size. To better provide comparisons, each data was separated into datasets of equal interval: 2M, 4M, 6M, 8M and 10M tuples (2×10^6 , 4×10^6 , 6×10^6 , 8×10^6 and 10^7).

In a first test run it was found that the different data distributions at those levels were interfering with the experiment, and so, to evaluate only the general distribution of the data and how it was organized, each tuple of each dataset was sampled from the full 2.4×10^7 original data.

In the end, this resulted in 12,83 GB of data converted to Frag-Cubing’s format, counting the datasets with the full 135 telemetries and the datasets with the filtered telemetries, resulting in 30 different data files (5 for the high-dimensional case, and 5 for each query).

For this paper, the names in Table 4.3 will be used to refer to each of these cubes. The cubes with 135 dimensions will be treated as “C0”, with “C1” to “C5” being the cubes with dimensions filtered for the telemetries in “Q1” to “Q5”.

Table 4.3 - Cube representations used in the experiment

ID	Query	Dimensions	Total Size
C0	-	135	11,29 GB
C1	Q1	6	0,44 GB
C2	Q2	3	0,34 GB
C3	Q3	2	0,22 GB
C4	Q4	2	0,20 GB
C5	Q5	3	0,34 GB

The process to separate the data was performed as follows:

- a) Select from telemetry database (PostgreSQL) the dimensions that are used in the query (ex. 'SELECT TM001, TM002 FROM telemetries');
- b) Filter first n tuples from that selection, where n is in 2×10^6 , 4×10^6 , 6×10^6 , 8×10^6 and 10^7 ;
- c) Save the results to a file and convert it to Frag-Cubing's input format, naming it cube i (eg. "Ci"), where i is one of the query identifiers;
- d) Load the file into Frag-Cubing and execute the relevant queries.

4.3.2 Results

For the algorithm to partition the queries, it was quickly apparent that the output was too broad and the difference between the queries was too hard to classify by an operator, as most relationships are not clear and would all require further investigation to validate, which would defeat the purpose of the algorithm. This led to using the most frequent queries as detailed in the previous sections, and the total abandonment of the algorithm, as the output could not be validated in a scientific manner.

Furthermore, INPE has only a few satellite operator experts, and for this satellite that has spanned multiple years of operations, the knowledge amounted to a single available person available for questioning, which is not enough for an objective scientific inquiry. Therefore, the separation in queries used was used as per the operator's experience, and thus are inherently biased. The algorithm needs more study and a robust dataset to be validated, and there are some hints in the literature trying to do, but data is sparse and the necessary information first needs to be made after human analysis. The use of the algorithm is then not recommended, and further

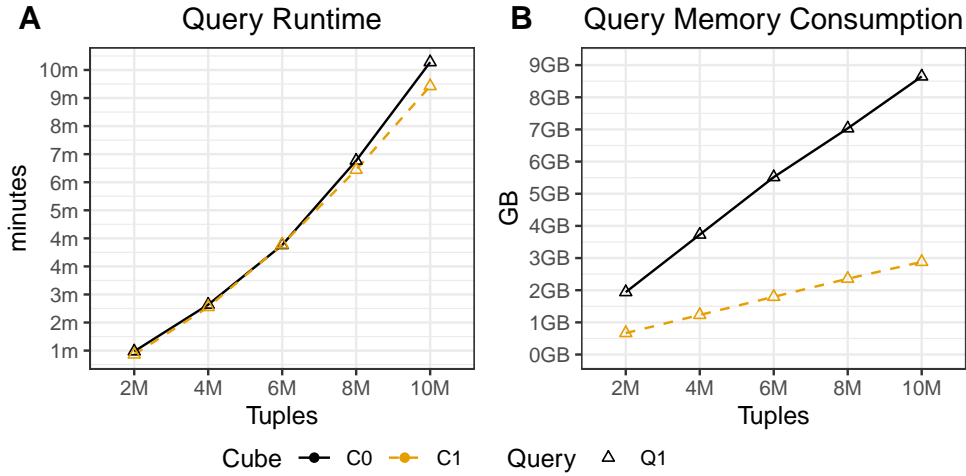
improvements to it will be out of the scope of this work.

Thus, this section will deal with the results from the experiment detailed in section 4.3.1. Each defined is compared with their execution in $C0$ and the relevant cube, with their memory and response times being measured by each.

4.3.2.1 Q1

Figure 4.1-A shows the query response times for query Q1, with the execution of the query in the $C0$ and $C1$ cubes. There's a speedup of about 10% with $C1$ for the $\mathcal{T} = 10^7$ case, for the query that uses the highest amount of dimensions on all the studied queries. Figure 4.1-B shows the query memory difference between $C0$ and $C1$ for query Q1. There's a clear advantage of $C1$ taking only one third of the memory that $C0$ takes to answer the same query.

Figure 4.1 - Query 1 results



(A) Total time to answer a query, including the time to read the data from the disk, build the cube and then answer the query Q1, with cubes $C0$ and $C1$. (B) Total memory consumption to answer Q1 with cubes $C0$ and $C1$.

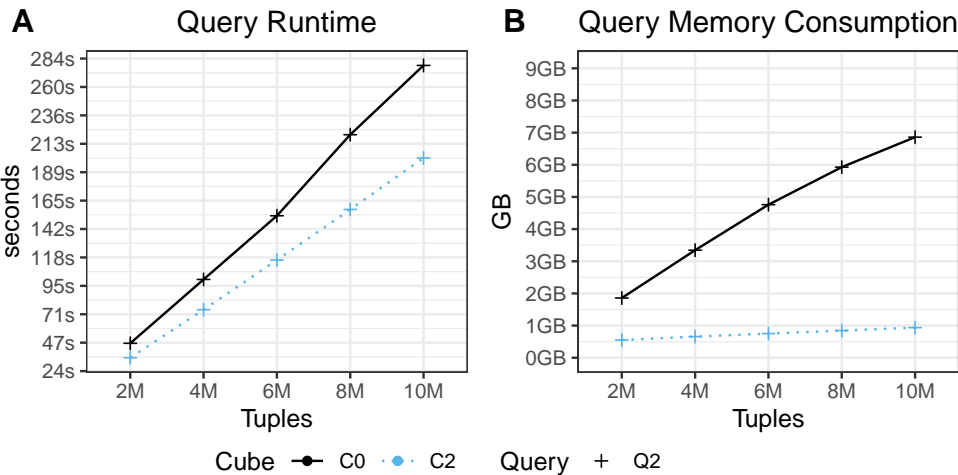
SOURCE: Author

4.3.2.2 Q2

Figure 4.2-A shows the query response times for query Q2, with the execution of the query in the $C0$ and $C2$ cubes. Here the difference when $\mathcal{T} = 10^7$ is $C2$ having

a runtime 40% faster than C0. Figure 4.2-B shows the query memory difference between C0 and C2 for query Q2. Again the result is C2 taking only a fraction (14%) of the same query under C0.

Figure 4.2 - Query 2 results



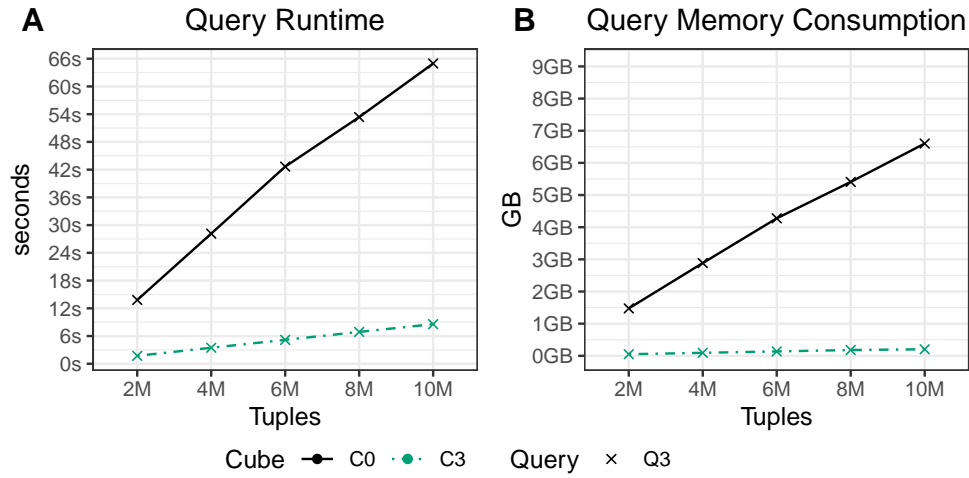
(A) Total time to answer a query, including the time to read the data from the disk, build the cube and then answer the query Q2, with cubes C0 and C2. (B) Total memory consumption to answer Q2 with cubes C0 and C2.

SOURCE: Author

4.3.2.3 Q3

Figure 4.3-A shows the query response times for query Q3, with the execution of the query in the C0 and C3 cubes. With less inquiries and dimensions this operation is expected to be faster, however the speedup is even greater: Q3 under C3 takes only 12% of the memory used by C0. Figure 4.3-B shows the query memory difference between C0 and C3 for query Q3, with C3 needing only 7% of the memory used by C0.

Figure 4.3 - Query 3 results




(A) Total time to answer a query, including the time to read the data from the disk, build the cube and then answer the query Q3, with cubes C0 and C3. (B) Total memory consumption to answer Q3 with cubes C0 and C3.

SOURCE: Author

4.3.2.4 Q4

Figure 4.4-A shows the query response times for query Q4, with the execution of the query in the C0 and C4 cubes. Another query with only two dimensions, and expected to be faster, with C4 taking 5% of the time used by C0. Figure 4.4-B shows the query memory difference between C0 and C4 for query Q4, showing the same speedup pattern.

Figure 4.4 - Query 4 results




(A) Total time to answer a query, including the time to read the data from the disk, build the cube and then answer the query Q4, with cubes C0 and C4. (B) Total memory consumption to answer Q4 with cubes C0 and C4.

SOURCE: Author

4.3.2.5 Q5

Figure 4.5-A shows the query response times for query Q5, with the execution of the query in the C0 and C5 cubes. Here with more dimensions than the previous two queries the speedup is less, but still substantial, with C5 taking only 43% of the runtime used by C0. Figure 4.5-B shows the query memory difference between C0 and C5 for query Q5, where the same figure of speedups are maintained.

Figure 4.5 - Query 5 results



(A) Total time to answer a query, including the time to read the data from the disk, build the cube and then answer the query Q5, with cubes C0 and C5. (B) Total memory consumption to answer Q5 with cubes C0 and C5.

SOURCE: Author

4.4 Summary and Analysis

For this experiment, the time dimension has the property of having a cardinality that is approximately equal to the amount of tuples ($\mathcal{C}_d = \mathcal{T}$, for a cardinality of dimension d and with a database of \mathcal{T} tuples), as each observation is time-stamped and therefore unique. This creates a considerable skew to the results with all telemetries, as with 10^7 tuples, a single dimension with $\mathcal{C}_d = 10^7$ is not suitable to be computed entirely, and very different from the other dimensions that have a maximum cardinality of $\mathcal{C}_d = 256$. As this time dimension was not considered in any query, this is expected to have been one of the reasons for the great difference in memory consumption between the queries and C0.

In summary, these results show that building the cube with only the dimensions for a given query can yield up to 80 times less memory for the cube construction, and using between 1% to 33% less memory to answer the same query on the same data, with variations depending on the amount of inquired dimensions. The speedup is so apparent that it'd be *faster* to read, build and then answer a query using one of the low-dimensional cubes (C1–5) than to directly query an already built data cube with all dimensions (C0), and is the main contribution of this work. Furthermore, the shell

fragment size parameter shows little benefit in reducing the memory consumption of the queries when they are performed in this manner, and should be kept at 1.

It is also important to highlight the query definitions with the help of a domain expert: most queries are low dimensional in nature, in line with Frag-Cubing's strengths. These queries are non-exhaustible and meant to be samples, but show that the common algorithmic approaches are suitable for the domain and can be made to improve memory implementation requirements.

5 IntervalFrag

This section describes the IntervalFrag algorithm, and the proposed architecture needed to implement the enhancements to the Frag-Cubing's algorithm.

5.1 Using Intervals in Inverted Indexes

- What problem are we trying to solve?
- The idea

5.2 Algorithm

- Simple implementation overview
- Insertion in the index
- Using iceberg conditions
- The Intersection problem and algorithm
- The skew influence
- Mention that there are ways to improve the algorithm further, and that they are further mentioned in appendix A

5.3 Results

Table 5.1 and Table 5.2 show the results of executing both algorithms to answer the queries defined in section 4.2, while using the cube structure defined as $C0$ in subsection 4.3.1, where all telemetries were used as a single file for each test, and then the query was executed, measuring the memory consumption in the first and query response time in the latter.

TODO: THE QUICK GRAPHS FOR EACH OF THESE, WITH JUST SIMPLE COMPARISONS WITH THE AMOUNT OF INQUIRED DIMENSIONS

Table 5.1 - IntervalFrag x Frag-Cubing, memory consumption in KiB

		Tuples				
Algorithm	Query	2×10^6	4×10^6	6×10^6	8×10^6	1×10^7
Frag-Cubing	Q1	1.908.708	3.674.784	5.447.864	6.953.424	8.557.348
	Q2	1.842.396	3.294.628	4.727.816	5.877.016	6.760.080
	Q3	1.448.280	2.836.592	4.236.496	5.362.128	6.502.628
	Q4	1.444.816	2.836.696	4.236.404	5.372.104	6.520.176
	Q5	1.607.456	3.024.996	4.445.800	5.591.052	6.650.456
IntervalFrag	Q1	504.428	845.804	1.196.504	1.455.472	1.651.552
	Q2	801.864	1.207.760	1.560.652	1.752.292	2.062.560
	Q3	388.652	707.588	1.030.392	1.237.324	1.415.472
	Q4	370.624	690.456	1.003.236	1.237.292	1.415.456
	Q5	540.788	895.272	1.232.520	1.412.280	1.604.288

Table 5.2 - IntervalFrag x Frag-Cubing, query response times in ms

		Tuples				
Algorithm	Query	2×10^6	4×10^6	6×10^6	8×10^6	1×10^7
Frag-Cubing	Q1	5.4691	188.634	310.455	421.409	523.772
	Q2	47.391	108.405	170.515	258.585	281.877
	Q3	1.557	3.089	4.637	6.497	7.597
	Q4	399	817	1.193	1.573	1.990
	Q5	7.138	21.668	33.483	49.590	59.428
IntervalFrag	Q1	1.946	4.712	6.981	9.198	11.508
	Q2	158.050	333.838	554.111	772.125	934.793
	Q3	3.570	7.064	10.655	14.812	17.714
	Q4	995	2.011	2.952	3.860	4.916
	Q5	4.871	11.837	18.477	26.176	32.649

6 Analysis and Discussion

In this chapter, a critical analysis of the algorithms is presented, as well as an overview of how useful are the results and what are their shortcomings. The results from chapters 5 and 4 show that simple approaches can be used to enhance the query response time for the selected queries, and can be easily ported to other domains and styles of computation.

Table 6.1 shows the characteristics in which each algorithm has showed to excel at. Frag-Cubing is still preferred when the data has a low degree of sequentiality, as there's little advantage in using the IntervalFrag scheme when the intervals are closer to the size of the original list. On those cases, IntervalFrag is discouraged, as the algorithm will be slower than Frag-Cubing's by simple virtue of needing more instructions to answer the same query, being up to 400% slower than the same query under Frag-Cubing.

Table 6.1 - Preferred algorithm to use

	Low Sequentiality	High Sequentiality	High Dimensionality	High Cardinality	High Skew
Computing the base cube	IntervalFrag	IntervalFrag	IntervalFrag	IntervalFrag	IntervalFrag
Subcube query	Frag-Cubing	IntervalFrag	IntervalFrag	Frag-Cubing ¹	FragCubing
Point query	Frag-Cubing	IntervalFrag	IntervalFrag	Frag-Cubing ¹	FragCubing
Low available RAM	IntervalFrag	IntervalFrag	IntervalFrag	IntervalFrag	IntervalFrag
Fast Query Reponse	Frag-Cubing	IntervalFrag	Frag-Cubing	IntervalFrag	Frag-Cubing

¹If there's high sequentiality, prefer IntervalFrag

In summary, in case the RAM available is low and the worst case query response times can be up to 4x slower than Frag-Cubing's, then IntervalFrag should be preferred as the main method of computing the data cube. In case the data have a very low sequentiality, and RAM is available, then using Frag-Cubing should still be preferred for the faster response times. IntervalFrag will excel at any dimension that has a high sequentiality, even if it also has a high cardinality, however dimensions that have a high cardinality will tend to have a low sequentiality in practice, and this usage might be rarer. The Skew parameter can influence the algorithm both

ways, as it does not necessarily mean that the dimension will have a higher or lower sequentiality and cardinalities.

When the dimensions have a high degree of sequentiality, then IntervalFrag excels, as it can not only answer the same queries much faster, but also using only a fraction of the memory used by Frag-Cubing. Furthermore, Frag-Cubing used much less memory to answer queries $Q1$, $Q2$ and $Q5$, with $Q4$ having a small difference and $Q3$ having no difference in memory usage in the end, when compared with cubes $C1$ to $C5$. All queries executed on the $C0$ cube with all dimensions used only a fraction of the memory needed to answer queries with IntervalFrag, they were however in general slower to answer.

From the tests made using Frag-Cubing and the different cubes ($C1$ to $C5$) tailored to specific queries, it was shown that the best algorithms can be further enhanced by doing some simple pre-processing of the queries, and depending on the type of query used they can drastically improve upon memory usage requirements, allowing for some frequent queries to be optimized and even allowing for queries that could not be answered under a $C0$ cube to be answered by smaller cubes. In chapter 4 it was shown that it is faster to load a smaller subset of the data in memory as prepared files when needed and then computing the answer from that file instead of querying a cube that was already loaded in memory, but that used the full dimensional capability of the data.

ADD AT LEAST ONE GRAPH OR TABLE COMPARING THEM. THE ONE USED FOR THE PRESENTATION IS FINE

It is important to note IntervalFrag had faster file reading speeds (about 12% faster) due to improvements made on the implementation, as well as a slightly more efficient set intersection algorithm, which were not backported to Frag-Cubing. This was done to preserve the Frag-Cubing algorithm's performance, as the original code was made for the C language in 2002 and the updated IntervalFrag implementation uses C++17 standards. Nonetheless, it was possible to compile Frag-Cubing using the same flags as IntervalFrag under the GNU C++ compiler, with minimal performance differences.

The difference in query response times from IntervalFrag and Frag-Cubing, even when using the same intersection algorithm, was due to IntervalFrag having to do more comparisons to answer the same query, and this implementation could not be further optimized without heavily skewing the response times to IntervalFrag's side,

by using other techniques that could also be ported to Frag-Cubing trivially. Further details on the intersection algorithms tested and their performance differences can be found on Appendix [A.1](#).

7 CONCLUSIONS

This work shows that it is possible to further optimize data cube algorithms by gathering information from the underlying data, and how this can be made to aid the end user’s experience by decreasing implementation requirements and improving response times.

7.1 Main contributions

One of the stated purposes of this work was to find ways of using the data’s domain characteristics to improve the satellite operator’s day to day activities, and this work has achieved three main results:

- a) A heuristic to discover related telemetries between satellite time series data and how to use this with the help of an operator to validate the relevant queries;
- b) Using the previous heuristic to enhance Frag-Cubing’s query response time and memory by pre-partitioning the data;
- c) Improving upon Frag-Cubing’s Inverted Index memory model by saving only intervals instead of the entire values, and thus reducing memory and query response times for some queries;

This is still all wrong. What do?

7.2 Future work

The natural evolution of this work would be to test it using other data cube algorithms, as there’s a great variety of them mentioned in section 3 and not all of them might be applicable to satellite telemetry data, or showcase useful performance metrics. On that note the use of bCubing (SILVA, 2015) will be interesting, as the inverted index separation into blocks can further improve upon the memory usage as described in this chapter.

The use of the gathered satellite data on other projects is also of interest, as there’s no public reliable dataset of satellite telemetry data that contains all relevant data and not just a subset of a subsystem, and this work showcases a volume that has information enough for the training of Machine Learning and Artificial Intelligence projects. Only projects that release full telemetry data are relatively simple CubeSat

projects, who do not generate a significant volume that is enough for the use of these algorithms. The author plans to release the dataset in a citable format for the use of the community in the near future.

This work also has the potential of improving query execution when dealing with multiple satellites, constellations and/or formations, it needing only the data to be gathered and the suitable cube format defined to be tested.

The relationship algorithms mentioned in [section 4.1](#) can be remade to use other different solutions, and combined with the shell-cubing method to generate only shells that have relationships above a certain strength. This was also one of the ideas to be developed during this work, which however had not enough time to be fully developed. This idea is best when paired with known "best available" techniques, like using the project ([LIBRESpaceFoundation...](#), 2021).

Furthermore the Set Intersection problem defined in [chapter 5](#) can be further optimized with recent advances not only in computer architectures, but also with regards to complexity and the validation of the algorithms in real world datasets. A preliminary investigation was performed, as a simple but not rigorous overview of the results is detailed in [Appendix](#) .

7.3 Final thoughts

The approach and architecture detailed in this work...

This work was developed entirely with open source software, and they will be made available later at <https://github.com/Yuri-M-Dias/SCD2>. Furthermore, there is a lack of good datasets that deal with satellite telemetry data available, perhaps this work can further contribute by allowing the usage of the dataset by making it public. The volume available here is much bigger than what is currently used by Machine Learning competitions, and the publication can further enhance work in this area.

REFERENCES

- ADAMSKI, G. Data Analytics for Large Constellations. In: **SpaceOps 2016 Conference**. [S.l.]: American Institute of Aeronautics and Astronautics, 2016. (SpaceOps Conferences). [23](#), [24](#)
- AZEVEDO, D. N. R.; AMBRÓSIO, A. M. Dependability in Satellite Systems: An Architecture for Satellite Telemetry Analysis. In: WORKSHOP EM ENGENHARIA E TECNOLOGIA ESPACIAIS, 1. (WETE)., 30 mar. - 1 abr. 2010, São José dos Campos. **Anais...** São José dos Campos: INPE, 2010. IWETE2010-1065, p. 6. ISSN 2177-3114. [1](#)
- AZEVEDO, D. N. R.; AMBRÓSIO, A. M.; VIEIRA, M. **Estudo sobre técnicas de detecção automática de anomalias em satélites**. PhD Thesis (PhD) — Instituto Nacional de Pesquisas Espaciais, São José dos Campos, 2011. [25](#)
- BEYER, K.; RAMAKRISHNAN, R. Bottom-up Computation of Sparse and Iceberg CUBE. In: **Proceedings of the 1999 ACM SIGMOD International Conference on Management of Data**. New York, NY, USA: ACM, 1999. (SIGMOD '99), p. 359–370. ISBN 978-1-58113-084-3. [18](#)
- BIMONTE, S. Open issues in Big Data Warehouse design. **Revue des Nouvelles Technologies de l'Information**, p. 10, 2016. [3](#), [8](#), [10](#)
- BOUSSOUF, L.; BERGELIN, B.; SCUDELER, D.; GRAYDON, H.; STAMMINGER, J.; ROSNET, P.; TAILLEFER, E.; BARREYRE, C. Big Data Based Operations for Space Systems. In: **2018 SpaceOps Conference**. [S.l.]: American Institute of Aeronautics and Astronautics, 2018. [8](#), [23](#), [24](#)
- CODD, E. F.; CODD, S.; SALLEY, C. Providing olap to user-analysts: An it mandate. In: . [S.l.: s.n.], 1998. [10](#)
- DING, B.; KÖNIG, A. C. Fast Set Intersection in Memory. **arXiv:1103.2409 [cs]**, mar. 2011. [63](#)
- DISCHNER, Z.; REDFERN, J.; ROSE, D.; ROSE, R.; RUF, C.; VINCENT, M. CYGNSS MOC; Meeting the challenge of constellation operations in a cost-constrained world. In: **2016 IEEE Aerospace Conference**. [S.l.: s.n.], 2016. p. 1–8. [24](#)

DOKA, K.; TSOUMAKOS, D.; KOZIRIS, N. Brown Dwarf: A fully-distributed, fault-tolerant data warehousing system. **Journal of Parallel and Distributed Computing**, v. 71, n. 11, p. 1434–1446, nov. 2011. ISSN 0743-7315. [25](#)

Dong Xin; Zheng Shao; Jiawei Han; Hongyan Liu. C-Cubing: Efficient Computation of Closed Cubes by Aggregation-Based Checking. In: **22nd International Conference on Data Engineering (ICDE'06)**. [S.l.: s.n.], 2006. p. 4–4. [19](#)

EDWARDS, T. Dealing with the Big Data - The Challenges for Modern Mission Monitoring and Reporting. In: **15th International Conference on Space Operations**. Marseille, France: American Institute of Aeronautics and Astronautics, 2018. ISBN 978-1-62410-562-3. [24](#)

EMANI, C. K.; CULLOT, N.; NICOLLE, C. Understandable Big Data: A survey. **Computer Science Review**, v. 17, p. 70–81, aug. 2015. ISSN 1574-0137. [3](#), [8](#)

EVANS, D. J.; MARTINEZ, J.; Korte-Stapff, M.; VANDENBUSSCHE, B.; ROYER, P.; RIDDER, J. D. Data Mining to Drastically Improve Spacecraft Telemetry Checking: A Scientist's Approach. In: **SpaceOps 2016 Conference**. [S.l.]: American Institute of Aeronautics and Astronautics, 2016, (SpaceOps Conferences). [24](#)

FEN, Z.; YANQIN, Z.; CHONG, C.; LING, S. Management and Operation of Communication Equipment Based on Big Data. In: **2016 International Conference on Robots Intelligent System (ICRIS)**. [S.l.: s.n.], 2016. p. 246–248. [24](#)

FERNÁNDEZ, M. M.; YUE, Y.; WEBER, R. Telemetry Anomaly Detection System Using Machine Learning to Streamline Mission Operations. In: **2017 6th International Conference on Space Mission Challenges for Information Technology (SMC-IT)**. [S.l.: s.n.], 2017. p. 70–75. [23](#), [24](#)

FILHO, A. C. J.; AMBRÓSIO, A. M.; FERREIRA, M. G. V.; LOUREIRO, G. The Amazonia-1 satellite's ground segment - challenges for implementation of the space link extension protocol services. In: INTERNATIONAL ASTRONOMICAL CONGRESS, 68. (IAC), 25-29 Sept., Adelaide, Australia. **Proceedings...** [S.l.], 2017. p. 1–12. [1](#)

GILLES, K. Flying Large Constellations Using Automation and Big Data. In: **SpaceOps 2016 Conference**. [S.l.]: American Institute of Aeronautics and Astronautics, 2016, (SpaceOps Conferences). [24](#)

GRAY, J.; BOSWORTH, A.; LYAMAN, A.; PIRAHESH, H. Data cube: A relational aggregation operator generalizing GROUP-BY, CROSS-TAB, and SUB-TOTALS. In: . [S.l.]: IEEE Comput. Soc. Press, 1996. p. 152–159. ISBN 978-0-8186-7240-8. [3](#), [11](#), [17](#)

HAN, J.; KAMBER, M.; PEI, J. **Data Mining: Concepts and Techniques, Third Edition**. 3 edition. ed. Haryana, India; Burlington, MA: Morgan Kaufmann, 2011. ISBN 978-93-80931-91-3. [4](#), [9](#), [11](#), [13](#), [14](#), [15](#), [16](#), [17](#), [18](#), [19](#), [25](#)

HEIDORN, P. B. Shedding Light on the Dark Data in the Long Tail of Science. **Library Trends**, v. 57, n. 2, p. 280–299, 2008. ISSN 1559-0682. [2](#)

HEINE, F.; ROHDE, M. PopUp-Cubing: An Algorithm to Efficiently Use Iceberg Cubes in Data Streams. In: **Proceedings of the Fourth IEEE/ACM International Conference on Big Data Computing, Applications and Technologies**. New York, NY, USA: ACM, 2017. (BDCAT '17), p. 11–20. ISBN 978-1-4503-5549-0. [25](#)

HENNION, N. Big-data for satellite yearly reports generation. In: **2018 SpaceOps Conference**. [S.l.]: American Institute of Aeronautics and Astronautics, 2018. [24](#)

ILLIMINE. **Software and Data Repository from Data Mining Research Group, Data and Information Systems (DAIS) Research Laboratory**. 2004. [35](#)

INMON, W. H.; HACKATHORN, R. D. **Using the Data Warehouse**. Somerset, NJ, USA: Wiley-QED Publishing, 1994. ISBN 978-0-471-05966-0. [9](#)

INOUE, H.; OHARA, M.; TAURA, K. Faster set intersection with SIMD instructions by reducing branch mispredictions. **Proceedings of the VLDB Endowment**, v. 8, n. 3, p. 293–304, nov. 2014. ISSN 2150-8097. [63](#)

KIMBALL, R.; ROSS, M. **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling**. Edição: 3rd. Indianapolis, IN: John Wiley & Sons, 2013. ISBN 978-1-118-53080-1. [9](#), [10](#)

KRAG, H.; SERRANO, M.; BRAUN, V.; KUCHYNKA, P.; CATANIA, M.; SIMINSKI, J.; SCHIMMERHORN, M.; MARC, X.; KUIJPER, D.; SHURMER, I.; O'CONNELL, A.; OTTEN, M.; MUÑOZ, I.; MORALES, J.; WERMUTH, M.; MCKISSOCK, D. A 1 cm space debris impact onto the Sentinel-1A solar array. **Acta Astronautica**, v. 137, p. 434–443, aug. 2017. ISSN 0094-5765. [7](#)

LAKSHMANAN, L. V. S.; PEI, J.; HAN, J. Quotient Cube: How to Summarize the Semantics of a Data Cube. In: **Proceedings of the 28th International Conference on Very Large Data Bases**. [S.l.]: VLDB Endowment, 2002. (VLDB '02), p. 778–789. [19](#)

LARSON, W. J.; WERTZ, J. R. (Ed.). **Space Mission Analysis and Design, 3rd Edition**. 3rd edition. ed. El Segundo, Calif. : Dordrecht ; Boston: Microcosm, 1999. ISBN 978-1-881883-10-4. [1](#), [7](#)

LI, X.; HAN, J.; GONZALEZ, H. High-dimensional OLAP: A Minimal Cubing Approach. In: **Proceedings of the Thirtieth International Conference on Very Large Data Bases - Volume 30**. [S.l.]: VLDB Endowment, 2004. (VLDB '04), p. 528–539. ISBN 978-0-12-088469-8. [19](#), [25](#), [26](#), [27](#)

LIBRESpaceFOUNDATION / Polaris / Polaris. 2021.
<https://gitlab.com/librespacefoundation/polaris/polaris>. [52](#)

LIMA, J. d. C. **SEQUENTIAL AND PARALLEL APPROACHES TO REDUCE THE DATA CUBE SIZE**. PhD Thesis (PhD) — Instituto Tecnológico de Aeronáutica, São José dos Campos, 2009. [12](#)

MAGALHÃES, R. O. de. **Estudo de avalanche térmica em um sistema de carga e descarga de bateria em satélites artificiais**. PhD Thesis (PhD) — Instituto Nacional de Pesquisas Espaciais, São José dos Campos, feb. 2012. [25](#)

MATEIK, D.; MITAL, R.; BUONAIUTO, N. L.; LOUIE, M.; KIEF, C.; AARESTAD, J. Using Big Data Technologies for Satellite Data Analytics. In: . [S.l.]: American Institute of Aeronautics and Astronautics, 2017. ISBN 978-1-62410-483-1. [23](#), [24](#)

MONTEIRO, D. V. **A FRAMEWORK FOR TRAJECTORY DATA MINING**. PhD Thesis (PhD), 2017. [25](#)

MOREIRA, A. A.; LIMA, J. d. C. Full and partial data cube computation and representation over commodity PCs. In: **2012 IEEE 13th International Conference on Information Reuse Integration (IRI)**. [S.l.: s.n.], 2012. p. 672–679. [10](#)

PIBIRI, G. E. Fast and Compact Set Intersection through Recursive Universe Partitioning. In: **IEEE Data Compression Conference**. [S.l.: s.n.], 2021. p. 10. [63](#)

PIBIRI, G. E.; VENTURINI, R. Techniques for Inverted Index Compression. **arXiv:1908.10598** [cs], aug. 2019. 63

RAMOS, M. P.; TASINAFFO, P. M.; de Almeida, E. S.; ACHITE, L. M.; da Cunha, A. M.; DIAS, L. A. V. Distributed Systems Performance for Big Data. In: LATIFI, S. (Ed.). **Information Technology: New Generations**. [S.l.]: Springer International Publishing, 2016, (Advances in Intelligent Systems and Computing). p. 733–744. ISBN 978-3-319-32467-8. 25

SCHULSTER, J.; EVILL, R.; PHILLIPS, S.; FELDMANN, N.; ROGISSART, J.; DYER, R.; ARGEMANDY, A. CHARTing the Future – An offline data analysis and reporting toolkit to support automated decision-making in flight-operations. In: **15th International Conference on Space Operations**. Marseille, France: American Institute of Aeronautics and Astronautics, 2018. ISBN 978-1-62410-562-3. 24

SILVA, R. R. **Abordagens para Cubo de Dados Massivos com Alta Dimensionalidade Baseadas em Memória Principal e Memória Externa: HIC e BCubing**. PhD Thesis (PhD) — Instituto Tecnológico de Aeronáutica, São José dos Campos, 2015. 4, 9, 19, 20, 27, 51

SILVA, R. R.; HIRATA, C. M.; LIMA, J. d. C. A Hybrid Memory Data Cube Approach for High Dimension Relations. In: HAMMOUDI, S.; MACIASZEK, L. A.; TENIENTE, E. (Ed.). **ICEIS 2015 - Proceedings of the 17th International Conference on Enterprise Information Systems, Volume 1, Barcelona, Spain, 27-30 April, 2015**. [S.l.]: SciTePress, 2015. p. 139–149. ISBN 978-989-758-096-3. 26

_____. Computing BIG data cubes with hybrid memory. **Journal of Convergence Information Technology**, v. 11, n. 1, p. 18, jan. 2016. 26

SILVA, R. R.; LIMA, J. d. C.; HIRATA, C. M. qCube: Efficient integration of range query operators over a high dimension data cube. **JIDM**, v. 4, n. 3, p. 469–482, 2013. 26

SIMÕES, R. E. d. O.; CAMARA, G.; QUEIROZ, G. R. de. Sits: Data analysis and machine learning using satellite image time series. In: Workshop de Computação Aplicada, 18. (WORCAP), 21-23 ago., São José dos Campos, SP. **Resumos...** [S.l.], 2018. p. 18. 25

TIAN, S.; WANG, P.; CHEN, X. Quantum Algorithm for Finding Sets Intersection. In: **2019 International Conference on Intelligent Computing**,

Automation and Systems (ICICAS). Chongqing, China: IEEE, 2019. p. 843–847. ISBN 978-1-72816-106-8. [63](#)

TOMINAGA, J.; FERREIRA, M. G. V.; AMBRÓSIO, A. M. Comparing satellite telemetry against simulation parameters in a simulator model reconfiguration tool. In: CERQUEIRA, C. S.; BÜRGER, E. E.; YASSUDA, I. d. S.; RODRIGUES, I. P.; LIMA, J. S. d. S.; OLIVEIRA, M. E. R. de; TENÓRIO, P. I. G. (Ed.). **Anais...** São José dos Campos: Instituto Nacional de Pesquisas Espaciais (INPE), 2017. ISSN 2177-3114. [25](#)

TROLLOPE, E.; DYER, R.; FRANCISCO, T.; MILLER, J.; GRISO, M. P.; ARGEMANDY, A. Analysis of automated techniques for routine monitoring and contingency detection of in-flight LEO operations at EUMETSAT. In: **2018 SpaceOps Conference**. Marseille, France: American Institute of Aeronautics and Astronautics, 2018. ISBN 978-1-62410-562-3. [23](#), [24](#)

WANG, Z.; CHU, Y.; TAN, K.-L.; AGRAWAL, D.; ABBADI, A. E.; XU, X. Scalable Data Cube Analysis over Big Data. **arXiv:1311.5663** [cs], nov. 2013. [26](#)

YANG, H.; HAN, C. Holistic and Algebraic Data Cube Computation Using MapReduce. In: **2017 9th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC)**. [S.l.: s.n.], 2017. v. 2, p. 47–50. [26](#)

YVERNES, A. Copernicus Ground Segment as a Service: From Data Monitoring to Performance Analysis. In: **15th International Conference on Space Operations**. Marseille, France: American Institute of Aeronautics and Astronautics, 2018. ISBN 978-1-62410-562-3. [3](#), [23](#), [24](#)

ZHANG, J.; LU, Y.; SPAMPINATO, D. G.; FRANCHETTI, F. FESIA: A Fast and SIMD-Efficient Set Intersection Approach on Modern CPUs. In: **2020 IEEE 36th International Conference on Data Engineering (ICDE)**. Dallas, TX, USA: IEEE, 2020. p. 1465–1476. ISBN 978-1-72812-903-7. [63](#)

ZHANG, X.; WU, P.; TAN, C. A big data framework for spacecraft prognostics and health monitoring. In: **2017 Prognostics and System Health Management Conference (PHM-Harbin)**. [S.l.: s.n.], 2017. p. 1–7. [8](#), [21](#), [22](#), [23](#), [24](#)

ZHAO, Q.; ZHU, Y.; WAN, D.; TANG, S. A Closed Frag-Shells Cubing Algorithm on High Dimensional and Non-Hierarchical Data Sets. In: **Proceedings of the**

12th International Conference on Ubiquitous Information Management and Communication. New York, NY, USA: ACM, 2018. (IMCOM '18), p. 6:1–6:8. ISBN 978-1-4503-6385-3. [26](#)

APPENDIX A - INTERSECTION ALGORITHMS

A.1 Problem

This is only a simple overview to show the importance of the problem and how different algorithms stack against each other.

The problem can be stated as follows: given sets S_1 and S_2 , find the elements that are present in both sets, their intersection, represented as $S_1 \cap S_2$. Furthermore, each element is ordered as unique, for they represented index positions and are thus always non-zero positive integers.

A.2 Algorithms

All wrong for now

UnorderedSet

Scalar

Li

BinaryLi

std::set_intersect

SIMD (SS2)

A.3 Experiments

To search for the best algorithm with real world data, an experiment was performed, much on the same framework as detailed in ??: C++ code, each test was executed 5 times and the median of the values was taken. As each technique is efficient with the memory usage, there wasn't much difference to be measured, so only the time necessary to intersect each list was measured. Each list was generated in interval from 2×10^6 to 1×10^7 , and all algorithms work on randomized ordered lists with the same size. This spread was intentional to mirror the worst cases in the Frag-Cubing algorithm.


Table A.1 showcases a summary of the experiment's results, this time caring only for the necessary time to answer the queries.

Table A.1 - Set Intersection Results, in milliseconds

Algorithm - N	2×10^6	4×10^6	6×10^6	8×10^6	1×10^7
UnorderedSet	867,802	1806,19	2586,04	3448,11	4213,15
Scalar	26,57	51,346	71,109	85,531	118,114
Li	26,531	45,596	66,19	86,234	108,603
BinaryLi	21,601	39,776	59,27	79,416	97,155
std::set_intersect	17,125	34,392	51,682	67,717	84,933
SIMD (SS2)	10,941	21,854	33,866	43,739	55,814

As the HashSet approach was the slowest approach, [Figure A.1](#) showcases the comparison between the other algorithms, that have comparable performances and are easier to visualize.

Figure A.1 - Set Intersection Algorithm results



Set intersection algorithms response times in milliseconds, ordered by the size of the input relation.

SOURCE: Author

The SIMD approach is clearly the fastest, however it is also dependant on processor architecture and even though the used SIMD instructions (SS2) are available on almost all modern CPUs, other newer instruction sets might not be, or might have different implementations depending on the CPU vendor, which complicates widespread implementation.

While these tests are interesting, there was not enough time to test some recent benchmarks that found the use of different algorithms and could improve the performance of each, as the use of compressed indexes in (PIBIRI; VENTURINI, 2019) show. Furthermore, the SIMD instruction set used here (SSE2) is limited even if it's support is widespread, with other instruction sets (SSE3, AVX, AVX512, etc) being available on modern CPUs and also available for use.

Some recent results that have not been properly explored in the data cube context as of yet: Recursive Universe Partitioning, a technique that uses the possible search space to partition the sets and execute the intersection (PIBIRI, 2021); FESIA, which combines the use of previous techniques with different SIMD computation techniques and a bitmap to decide which algorithm is more suitable for use depending on the set size (ZHANG et al., 2020); and simpler implementations that reduce branch mispredictions (INOUE et al., 2014), and the use of pre-processed dictionaries to greatly aid in the computation (DING; KÖNIG, 2011). There's even an algorithm to compute the set intersection in $\mathcal{O}(1)$ by using a quantum computer (TIAN et al., 2019), however that approach is likely not implementable for any significant dataset in the near future.

Further testing is necessary when dealing with lists of varying sizes, that would showcase the improvements of certain algorithms over others, and the incorporation of these algorithms into a real-world dataset for accurate tests.

ANNEX A - PUBLICATIONS

This annex showcases the publications that resulted from this work, and from the general Master's effort. Table A.1 shows the summary of the published, and currently expecting to be published articles.

Table A.1 - Resulting published work

Name	QUALIS	SCOPUS Percentile	Source	Status
WETE 2018	NA - Conference	NA		Published
IAC 2019	NA - Conference	NA		Published
MDPI Information	B2 (A4)	47%	-	Accepted, later retracted
IEEE Latin America Transactions	B2	61%	-	Submitted
IntervalFrag	-	-	-	Writing
Inverted Index Intersection in Data Cubes	-	-	-	Writing

Furthermore, the table shows that the last two articles are being written, and will be published shortly with the results derived from this work.

Tem os artigos do CubeDesign + Jenny/LIT que faltam aqui, coloco eles ou não?
Eu tive pouca atuação, não sei se é relevante colocar aqui

PUBLICAÇÕES TÉCNICO-CIENTÍFICAS EDITADAS PELO INPE

Teses e Dissertações (TDI)

Teses e Dissertações apresentadas nos Cursos de Pós-Graduação do INPE.

Manuais Técnicos (MAN)

São publicações de caráter técnico que incluem normas, procedimentos, instruções e orientações.

Notas Técnico-Científicas (NTC)

Incluem resultados preliminares de pesquisa, descrição de equipamentos, descrição e ou documentação de programas de computador, descrição de sistemas e experimentos, apresentação de testes, dados, atlas, e documentação de projetos de engenharia.

Relatórios de Pesquisa (RPQ)

Reportam resultados ou progressos de pesquisas tanto de natureza técnica quanto científica, cujo nível seja compatível com o de uma publicação em periódico nacional ou internacional.

Propostas e Relatórios de Projetos (PRP)

São propostas de projetos técnico-científicos e relatórios de acompanhamento de projetos, atividades e convênios.

Publicações Didáticas (PUD)

Incluem apostilas, notas de aula e manuais didáticos.

Publicações Seriadas

São os seriados técnico-científicos: boletins, periódicos, anuários e anais de eventos (simpósios e congressos). Constam destas publicações o Internacional Standard Serial Number (ISSN), que é um código único e definitivo para identificação de títulos de seriados.

Programas de Computador (PDC)

São a seqüência de instruções ou códigos, expressos em uma linguagem de programação compilada ou interpretada, a ser executada por um computador para alcançar um determinado objetivo. Aceitam-se tanto programas fonte quanto os executáveis.

Pré-publicações (PRE)

Todos os artigos publicados em periódicos, anais e como capítulos de livros.